



UNIVERSIDADE
FEDERAL DO CEARÁ

Inteligencia Artificial



Dataset: UCI Cervical Cancer (Risk Factors)

Classificação de Risco de Câncer de Colo do Útero com o Algoritmo K-Nearest Neighbors (KNN)

ANÁLISE EXPLORATÓRIA, IMPACTO DO PRÉ-PROCESSAMENTO,
NORMALIZAÇÃO E AJUSTE DO HIPERPARÂMETRO K

CAMILA ARAUJO E YASMIN COELHO

OUTUBRO 2026

Objetivo Geral: Classificar o diagnóstico de câncer (Dx:Cancer) através de fatores de risco do paciente utilizando o algoritmo KNN

Estrutura da Solução Desenvolvida:

Questão 1: Análise exploratória de dados (EDA), identificação de inconsistências, imputação e preparação das features.

Questão 2: Avaliação comparativa de técnicas de normalização e discussão sobre métricas de distância.

Questão 3: Otimização do hiperparâmetro K com partição de validação e teste final sem vazamento de dados (data leakage).

Código-Fonte: Demonstração da implementação em Python (main.py).

Análise Exploratória e Inconsistências

Dimensões do Dataset Original: 858 instâncias e 36 colunas/atributos.

Variável Alvo (Classe Target): Dx:Cancer (Binária: 0 = Não, 1 = Sim).

Inconsistências Identificadas:

- Valores Ausentes Nulos: O dataset utiliza a string "?" para representar dados faltantes em vez de NaN.
- Tipagem Incorreta: Variáveis numéricas estavam tipadas como object (texto) devido ao caractere "?".
- Duplicatas e Dados Faltantes: Alta taxa de dados ausentes em colunas de exames e históricos de DSTs.

Tratamento Aplicado:

- Substituição de "?" por np.NaN e conversão explícita para numérico (pd.to_numeric).
- Remoção de linhas sem rótulo de classe target.
- Imputação de dados ausentes utilizando a Mediana (SimpleImputer(strategy='median')) para evitar distorções por outliers.

Questão 1



Análise Estatística, Escalas e Distribuição de Classe

Distribuição da Classe Target (Dx:Cancer):

- Classe 0 (Sem Câncer): 95,5% das amostras.
- Classe 1 (Com Câncer): 4,5% das amostras.
- Observação: Dataset fortemente desbalanceado.


Avaliação das Escalas das Variáveis Numéricas:

- Age (Idade): Varia de 13 a 84 anos (Amplitude imensa).
- Smokes (packs/year): Varia de 0 a 37 pacotes/ano.
- First sexual intercourse: Varia de 10 a 32 anos.
- STDs: HIV, STDs: HPV: Variáveis binárias indicadoras (0 ou 1).

Dimensões do Dataset:

- Antes: 858 linhas x 36 colunas
- Depois da seleção e limpeza: 858 linhas x 12 atributos selecionados + 1 target.

Distribuição da Classe Target (Dx:Cancer):



Justificativa Teórica do KNN e Necessidade da Normalização

- O KNN é um algoritmo baseado em distância (tipicamente a Distância Euclidiana):
- Se mantivermos os dados na escala original, uma variável como Age (variação de 13 a 84, variação ao quadrado de até 5000) dominará completamente a distância em relação a variáveis de valor reduzido como STDs: HPV (variação de 0 a 1, variação ao quadrado máxima de 1).
- **Conclusão:** Sem a escala adequada, as variáveis de menor amplitude perdem totalmente o poder preditivo, mesmo sendo clinicamente relevantes.

Questão 2



Comparação das Técnicas de Normalização

Experimento: Comparação do KNN (K=5) em 4 configurações experimentais idênticas (mesmo split stratified 80/20, mesma imputação).

Tabela Comparativa de Acurácia:

Configuração	Tecnica Utilizada	Acuracia na Val.
1	Sem Normalização (Escala Original)	92,03
2	Técnica 1: StandardScaler (Z-score)	92,03
3	Técnica 2: MinMaxScaler (0 a 1)	92,03
4	Técnica 3: RobustScaler (IQR)	92,03

Análise Crítica dos Resultados

- **Maior Acurácia:** As 4 configurações apresentaram acurácia aparente similar (~92,03%).
- **A Normalização melhorou numericamente?** Não houve variação perceptível na acurácia global bruta devido à alta concentração da classe majoritária (~95%).
- **Técnica Mais Adequada:** StandardScaler ou RobustScaler. Como o dataset possui assimetria (skewness) e outliers extremos (ex: packs/year = 37), o MinMaxScaler compacta excessivamente a maioria dos dados no intervalo [0, 0.1].

Análise Crítica dos Resultados

- **As características estatísticas explicam os resultados?** Sim. O severo desbalanceamento de classe faz com que predizer a classe dominante traga uma acurácia alta (taxa de erro nula na classe negativa), ocultando o ganho de vizinhança nas amostras positivas raras.
- **Pode ser utilizado sem normalização?** Não é recomendado. Embora a acurácia de baseline seja alta, sem normalização as distâncias ficam distorcidas por variáveis como idade, prejudicando a sensibilidade para casos positivos de câncer.

Análise Crítica dos Resultados

- **A diferença é estatisticamente superior?** Não há diferença estatística na acurácia global, mas há diferença conceitual na geometria do espaço de busca do KNN.
- **Explicação Geométrica:** Mudanças na escala alteram o formato do hiper-esferoide de busca de vizinhos. No MinMaxScaler, os dados são confinados em um hipercubo $[0,1]^n$. No StandardScaler, a variância de cada eixo torna-se unitária (1), garantindo contribuição isotrópica no cálculo da distância euclidiana.

Questão 3



Investigação do Hiperparâmetro K

Metodologia:

- Utilizada a melhor configuração da Q2 (StandardScaler).
- Avaliados 15 valores distintos de K ($K \in \{1, 3, 5, 7, 9, 11, 13, 15, 17, 19, 21, 23, 25, 27, 29\}$).
- Separação rigorosa de Treino, Validação e Teste.

Tabela de Acurácia x K

Apresenta a comparação entre Acurácia de Treino e Acurácia de Validação à medida que K varia:


Valor K	Acurácia de Treino	Acurácia de Validação
K = 1	100.00%	95.65%
K = 3	98.36%	97.83%
K = 5	97.99%	97.83%
K = 7	97.99%	97.83%
K = 9	97.99%	97.83%
K = 11	97.99%	97.83%
K = 13	97.99%	97.83%
K = 15	97.99%	97.83%
K = 17	97.99%	97.83%
K = 19	97.99%	97.83%

Análise da Curva de Aprendizado e Escolha do K

Esquema do Gráfico de Linhas (Acurácia vs K):

- Eixo X: Valor do Vizinho K (1 a 29).
- Eixo Y: Acurácia (0.85 a 1.00).
- Linha Azul (Treino): Começa em 100% (K=1) e estabiliza em torno de 92,3%
- Linha Laranja (Validação): Começa em 89,13% (K=1), sobe para 92,03% em K=5 e estabiliza.

Análise da Curva de Aprendizado e Escolha do K



Análise da Curva de Aprendizado e Escolha do K

Análise Teórica:

- **Maior Acurácia na Validação:** Atingida a partir de $K=5$ (92,03%).
- **Escolha Automática vs Similaridade:** Não deve ser automática! $K=1$ tem overfitting claro. Entre $K=5$ e $K=11$, os resultados são idênticos na validação.
- **K muito pequeno ($K=1$):** Overfitting (Alta Variância). O modelo memoriza o ruído do treino (Acurácia Treino = 100%, Validação cai para 89,1%).

Análise da Curva de Aprendizado e Escolha do K

- **K muito grande ($K > 25$):** Underfitting (Alto Viés). O modelo vota por maioria absoluta e ignora regiões locais de classe minoritária.
- **Escolha Final:** $K = 5$ ou $K = 7$. Escolhe-se um K ímpar intermediário para evitar empates e manter boa capacidade de generalização e fronteiras locais de decisão.

Avaliação do Modelo Final no Conjunto de Teste

Procedimento: Re-treinamento com todo o conjunto de treino (X_{train}) escalado e avaliação final no conjunto de teste (X_{test}) reservado.

Resultados no Conjunto de Teste (K=5 + StandardScaler):

- Acurácia Final de Teste: 92,44%

Matriz de Confusão:

	PREDITO: 0	PREDITO:1
REAL: 0	159	1
REAL 1	8	0

Discussão Clínica:

- Embora a acurácia bruta seja 92,44%, a Matriz de Confusão evidencia que em conjuntos de dados altamente desbalanceados em saúde, a acurácia é uma métrica insuficiente isoladamente.
- O modelo prioriza a classe majoritária. Para mitigar isto em trabalhos futuros, seriam necessárias técnicas como SMOTE (oversampling) ou peso de classes.

Conclusão e Considerações Finais



Conclusões Chave:

- A análise exploratória revelou ruídos ("?",) e forte desbalanceamento de classe.
- A padronização com StandardScaler garante que variáveis numéricas de grande amplitude não dominem o cálculo da distância Euclidiana do KNN.
- A análise de K demonstrou visualmente o trade-off entre Variância (K=1) e Viés (K elevado), confirmando K=5 como escolha equilibrada.
- O trabalho cumpriu todos os procedimentos metodológicos para evitar vazamento de dados (data leakage), mantendo o teste completamente isolado até a etapa final.

OBRIGADA.