

Apresentação do dataset

Heart Disease



Índice

- **Apresentação do Dataset**
- **Análise do Dataset**
- **Inconsistências Encontradas**
- **Análise Estatística**
- **Distribuição de Classes**
- **Avaliação das Escalas das Variáveis Numéricas**
- **Versão Final do Dataset para Q2**

Apresentação do dataset

O dataset Heart Disease é uma base de dados clássica para a previsão de doença cardíaca com base nos resultados de uma série de exames associados. Foram coletados dados de 303 pacientes da cidade de Cleveland, EUA, para compor o dataset. O conjunto de dados é avaliado com um grau de doença cardíaca (0-4), sendo 0 saudável.

Análise do Dataset

Para a análise inicial foi identificado as dimensões do dataset (303, 14), os tipos de dados sendo int e float e identificação da variável de classe (Target) sendo num.

Inconsistências Encontradas

- ✓ Identificação de valores nulos na linhas ca (número de vasos sanguíneo principais) sendo 4 e na thal (talassemia) sendo 2.
- ✓ Identificado a presença de outliers
- ✗ Não foi identificado linhas duplicadas.

Inconsistências Encontradas

Medidas tomadas:

- Remoção dos valores ausentes.
- Criação de uma nova variável chamada heart_limpo sem os valores nulos.
- Criação da variável X_limpo onde vai armazenar todos os valores de heart_limpo com exceção da coluna num.
- Optou-se por não remover os outliers pois valores extremos em dados clínicos podem representar observações reais.

Avaliação das Escalas das Variáveis Numéricas

	Variável	Média	Mediana	Desvio padrão	Mín.	Máx.
Idade	age	54,54	56	9,05	29	77
Pressão arterial	trestbps	131,69	130	17,76	94	200
Colesterol	chol	247,35	243	52	126	564
Freq cardíaca	thalach	149,6	153	22,94	71	202
Depressão segmento ST	oldpeak	1,06	0,8	1,17	0	6,2

Avaliação das Escalas das Variáveis Numéricas

A análise estatística mostrou que as variáveis numéricas apresentam escalas e amplitudes diferentes. Enquanto oldpeak varia de 0 a 6,2, chol varia de 126 a 564, por exemplo. Como o KNN utiliza a distância entre as observações para determinar seus vizinhos, a manutenção das variáveis em suas escalas originais pode fazer com que atributos com valores numericamente maiores exerçam maior influência no cálculo da distância. Dessa forma, é necessário aplicar uma transformação de escalas.

Distribuição das Classes

Foi constatada uma distribuição desbalanceada da variável num, com alguns grupos tendo pouquíssimas observações, o que prejudica muito a performance do modelo adotado na pesquisa. Em razão disso, optamos por binarizar o alvo, simplificando da escala (0-4) para (0-1), onde 1 agora representa todas as classes (1-4). Isso nos permite responder a questão mais fundamental que é a presença de doença.

Versão Final do Dataset

Divisão dos dados entre 80% para treino e 20% para teste.

Dimensão do dataset para treino: (237, 28)

Dimensão do dataset para teste: (60, 28)

- **Objetivo do experimento**
- **Técnicas utilizadas**
- **Tabela comparativa de acurácias**
- **Análise dos resultados**

Objetivos do Experimento

- **Maior acurácia**
- **Normalização melhorou o KNN?**
- **Técnica mais adequada**
- **Relação com as características da Questão 1**
- **Uso do dataset sem normalização**
- **A diferença entre as acurácias é significativa?**
- **Por que as técnicas de normalização podem produzir resultados diferentes?**

Configurações Testadas

- Config. 1 – Sem normalização: dados numéricos originais
- Config. 2 – Z-score: média 0 e desvio padrão 1
- Config. 3 – Min-Max: escala entre 0 e 1
- Config. 4 – $\text{Log}(1 + x)$: transformação logarítmica

Condição

- Algoritmo: KNN com $K = 7$
- Mesma divisão em treino e teste

Tabela Comparativa de Acurácias

CONFIGURAÇÃO	TÉCNICA UTILIZADA	ACURÁCIA	DIFERENÇA SEM NORMALIZAÇÃO
1	Sem normalização	0.71	—
2	Z-score	0.90	+0,19
3	Min-Max-Score	0.85	+0,14
4	Log(log1p)	0.83	+0,12

Análise dos Resultados

Qual configuração apresentou a maior acurácia?

- Z-Score com 0.90% de acurácia

A normalização melhorou o desempenho do KNN?

- Sim.
- Z-score com +0.19 pontos acima
- Min-Max: +0.14 acima.
- Log: + 0.12 acima.

Qual técnica de normalização foi mais adequada?

- Z-score com 0.90%, vai equilibrar as escalas para que nenhuma domine

Análise dos Resultados

- **As características estatísticas identificadas na Questão 1 ajudam a explicar os resultados?**

Sim. Escalas muito diferentes explicam o pior resultado sem normalização e as diferenças entre as técnicas

O dataset pode ser utilizado sem normalização?

- Não recomendado porque a acurácia caiu para 0.71%

Análise dos Resultados

A diferença entre as acurácias é suficiente para afirmar que uma configuração é claramente superior às demais?

- Não de forma conclusiva. A diferença é pequena entre os métodos de normalização

Considerando o funcionamento do KNN e o cálculo de distâncias entre as amostras, explique por que as técnicas de normalização podem produzir resultados diferentes.

- Variáveis de escala maior dominam a distância

Mudando os vizinhos, a classe prevista pode mudar, e a acurácia também


- **Investigando Qual Valor de (K) Produz o Melhor Desempenho no Algoritmo K-Nearest Neighbors**
- **Analizando Gráfico e Tabela**
- **O Que Acontece Com o (K)**
- **O Gráfico Apresenta Indícios de Sobreajuste ou Subajuste?**
- **Qual Valor de (K) Considera-se Mais Adequado para o problema?**
- **Treinando o Modelo com a Configuração Escolhida**

Investigando Qual Valor de (K) Produz o Melhor Desempenho no Algoritmo K-Nearest Neighbors

OBJETIVO E CONFIGURAÇÃO GERAL

- Encontrar o valor de K que dá o melhor desempenho no KNN
- Dados: dataset Heart Disease
- Normalização: StandardScaler (Z-score)
- Valores Testados: K de 1 a 25
- Treino 60%, validação 20% e teste 20%
- Treino e validação servem para escolher o K, e o teste fica reservado para a avaliação final

Gráfico e Tabela



K	Acurácia de treinamento	Acurácia de validação
1	1	0,7333
2	0,8644	0,7667
3	0,8983	0,8333
4	0,8757	0,8167
5	0,8814	0,8333
6	0,8701	0,8333
7	0,8701	0,8167
8	0,8475	0,8167
9	0,8475	0,8167
10	0,8588	0,8
11	0,8531	0,8167
12	0,8588	0,7833
13	0,8701	0,8
14	0,8531	0,7833
15	0,8644	0,75
16	0,8531	0,7833

Analizando Gráfico e Tabela

K Com Maior Acurácia de Validação

A maior acurácia de validação foi 0,8333, e ela apareceu em três valores de K: 3, 5 e 6
O código escolheu $K = 3$.

Esse valor deve ser escolhido automaticamente?

- A validação tem 60 amostras, ou seja, cada amostra a mais ou a menos muda a acurácia em cerca de 1.7%
- Diferença de acertos pequena.
- K do 3 ao 11 tem desempenho parecido
- Olhar comportamento geral das curvas e a capacidade de generalização do modelo.

O Que Acontece Com o (K)

Quando Ele é Muito Pequeno

- **O que o modelo faz:** busca o único paciente mais parecido e copia o diagnóstico dele.
- **Consequência no treino:** o vizinho mais próximo de cada paciente é ele mesmo, então a acurácia é 1,0
- **Consequência na validação:** com pacientes novos, o modelo copia o vizinho errado e a acurácia cai para 0,7333
- **Diferença entre as linhas:** 0,27, a maior do gráfico
- **Conclusão:** o modelo decorou o treino, incluindo o ruído, e não generaliza, o que é sobreajuste, com alta variância

O Que Acontece Com o (K)

Quando Ele é Muito Grande

- **O que o modelo faz:** consulta 12 a 25 pacientes, e muitos têm perfil bem diferente do paciente analisado.
- **Problema:** Reflete a tendência geral do conjunto, e não as características daquele paciente.
- **Consequência:** a decisão fica suavizada demais e o modelo perde as diferenças entre perfis.
- **No treino:** estabiliza em cerca de 0,85.
- **Na validação:** fica entre 0,75 e 0,80, abaixo dos 0,8333 da melhor região.
- **Diferença entre as linhas:** pequena, mas em um patamar baixo.
- **Conclusão:** o modelo ficou simples demais, o que é subajuste leve, com alto viés.

O Gráfico Apresenta Indícios de Sobreajuste ou Subajuste?

Sobreajuste (Overfitting)

- Modelo decora os dados de treino em vez de aprender o padrão real
- $K = 1$, Treino está com 1 e a Validação está em 0.73

Subajuste (Underfit)

- Um modelo é simples demais para capturar os padrões e as relações reais dos dados.
- As duas curvas ficam mais próximas, mas em um patamar mais baixo.

Qual Valor de (K) Considera-se Mais Adequado para o problema?

K = 5

O $K=5$ tem a mesma validação do $K=3$ e uma diferença menor entre treino e validação, ou seja, generaliza melhor. Ele também é um modelo mais suave, com 5 vizinhos em vez de 3, e é ímpar, então não há empate na votação. O $K=6$ tem a menor diferença, mas é par, e o empate de votos (3 contra 3) é resolvido de forma arbitrária.

Treinando o Modelo com a Configuração Escolhida

K = 5

Validação - 0,8333 (50 em 60)

Teste - 0,8667 (52 em 60)

A escolha do K=5 foi baseada na validação e na diferença entre treino e validação. Chegamos a rodar o teste com outros valores de K durante o desenvolvimento, mas não os usamos como critério.

Dúvidas?

