

Inadimplência de Clientes de Cartão de Crédito

Inteligência Artificial

Gabriely Moura Altenhofen (580034)

Habacuqui Doglas Costa Alves (585774)



Esta pesquisa teve como objetivo analisar o caso de inadimplência de clientes em Taiwan e comparar a precisão preditiva da probabilidade de inadimplência entre seis métodos de mineração de dados.

Características do conjunto de dados

Multivariado

Área temática

Negócios

Tarefas associadas

Classificação

Tipo de recurso

Inteiro, Real

Instâncias

30000

Características

23

Questão 1

PRINCIPAIS RESULTADOS OBTIDOS

Dimensões e tipos: 30.000 linhas e 24 colunas (23 variáveis de entrada e a classe DEFAULT; o ID já saiu na leitura). Todas são `int64`, inclusive as categóricas.

Valores nulos: nenhum.

Duplicatas: 35 linhas.

Códigos inválidos: EDUCATION traz 0 (14 linhas), 5 (280) e 6 (51), totalizando 345 linhas fora da documentação. MARRIAGE traz 0 (54 linhas).

Valores atípicos, mas legítimos: 3.932 faturas negativas (BILL_AMT), nenhum pagamento negativo, e $PAY_x = -2$ (2.759 linhas) e 0 (14.737 linhas).

Classes: 77,88% pagaram (23.364) e 22,12% não pagaram (6.636). Um modelo que sempre prevê “pagou” já acerta **77,88%** (baseline).

Escalas: as colunas de dinheiro têm amplitude de 0,4 a 1,8 milhão (LIMIT_BAL 990.000; BILL_AMT3 1.821.353), enquanto PAY_1...PAY_6 têm amplitude 10 e AGE 58. A razão entre a maior e a menor amplitude chega a **1.821.353 vezes**.

Assimetria e outliers: LIMIT_BAL tem skew 0,99; BILL_AMT tem 2,66 a 3,09; PAY_AMT tem 10,6 a 30,4 (PAY_AMT2 chega a 1,68 milhão com mediana de 2.009). Cerca de 8–10% dos valores de BILL_AMT e PAY_AMT são outliers pela regra do IQR.

JUSTIFICATIVA PARA CADA COLUNA OU LINHA REMOVIDA

Coluna ID: é só um número de identificação. No KNN entraria na distância como se fosse uma característica, e clientes com IDs próximos pareceriam vizinhos sem relação alguma com o pagamento.

35 linhas duplicadas: repetem uma amostra já existente. No KNN, uma cópia idêntica fica a distância zero e vira o vizinho mais próximo, o que infla a acurácia artificialmente.

Nenhuma linha foi removida pelos códigos inválidos: seriam 399 linhas perdidas (345 + 54) sem necessidade, então o tratamento foi agrupar.

Questão 1

Tratamento aplicado às inconsistências

- **EDUCATION = 0, 5, 6 → 4 (“outros”)** (a categoria 4 passa de 123 para 468 linhas) e **MARRIAGE = 0 → 3 (“outros”)**. São códigos fora da documentação e poucas amostras, então agrupar preserva as linhas.
- **SEX** convertido para 0/1.
- **One-hot em EDUCATION e MARRIAGE:** são categorias sem ordem. Com 1, 2, 3, 4, o KNN trataria “pós-graduação” (1) como 3 vezes mais distante de “outros” (4) do que de “graduação” (2), o que não existe nos dados. Com colunas 0/1, todas as categorias ficam equidistantes.
- **Mantidos de propósito:**
 - faturas negativas, que representam crédito a favor do cliente (dado real);
 - $PAY_x = -2$ e 0 , que são os valores mais frequentes (a categoria 0 tem quase metade das linhas) e remover distorceria o dataset;
 - os outliers, que são clientes reais; seu efeito é tratado pela normalização na Questão 2.

Questão 1

Justificativa para normalizar ou padronizar

O KNN classifica pela distância euclidiana, que soma as diferenças ao quadrado. Uma diferença de R\$ 50.000 no limite contribui com 2,5 bilhões, e 3 meses de atraso contribuem com 9. As colunas de dinheiro (13 das 20 numéricas, com amplitudes de centenas de milhares) dominam a distância, e as variáveis de atraso PAY_1 ...PAY_6, com amplitude 10, quase não pesam. O KNN não aprende pesos para corrigir isso, então **normalizar ou padronizar é necessário**. A forte assimetria e os outliers mostram ainda que a técnica escolhida pode fazer diferença, o que é testado na Questão 2.

Versão final: O arquivo `dataset_preparado_questao2.csv`, gerado pelo script, com 29.965 linhas e 29 colunas.

	Linhas	Colunas
Antes	30.000	24 (25 contando o ID)
Depois	29.965	29

Questão 2

Todas as configurações usaram o mesmo split (treino 17.979 / validação 5.993 / teste 5.993), K = 5 e distância euclidiana, com o scaler ajustado só no treino.

Configuração	Técnica utilizada	Acurácia (validação)	Recall classe 1	F1 classe 1
1	Sem normalização	0,7552	0,1795	0,2450
2	MinMaxScaler	0,7934	0,3213	0,4077
3	StandardScaler	0,7969	0,3462	0,4300
4	Logarítmica (log1p com sinal)	0,7852	0,3069	0,3874

Questão 2

1. Qual configuração teve a maior acurácia? A configuração **3, StandardScaler**, com **0,7969**. Ela também teve o melhor recall (0,3462) e o melhor F1 (0,4300).

2. A normalização melhorou o desempenho? (numericamente) Sim. Sem normalização a acurácia foi de 0,7552. Com normalização subiu **+3,82 p.p.** (MinMax), **+4,17 p.p.** (Standard) e **+3,00 p.p.** (logarítmica). Os três ganhos são maiores que a margem de erro de 1,02 p.p. O efeito é ainda maior no **recall da classe 1**, que passa de 0,18 para 0,35 com o Standard, quase o dobro: o modelo identifica quase o dobro dos inadimplentes.

3. Qual técnica foi mais adequada? O **StandardScaler**. Ele lidera nas três métricas (acurácia, recall e F1), e a ordem Standard > MinMax > Logarítmica > Sem normalização se repete em todas elas, o que reforça a conclusão. Ele funciona melhor porque coloca as 20 variáveis numéricas em uma escala comparável (média 0, desvio 1). O MinMax também ajuda, mas os outliers esticam o mínimo e o máximo e comprimem a maioria dos clientes numa faixa estreita. A logarítmica reduz a assimetria, mas **não iguala as escalas**: depois do log, as colunas de dinheiro ainda variam de 0 até cerca de 14 (e as faturas de cerca de -12 a +14), enquanto os atrasos PAY_x variam só de cerca de -1,1 a 2,2. As variáveis de dinheiro continuam pesando mais na distância, o que explica o resultado inferior aos outros dois.

4. As características da Questão 1 ajudam a explicar? Sim, em três pontos:

- **Escalas muito diferentes** (razão de 1,8 milhão de vezes): explicam por que sem normalização o modelo vai pior e quase não identifica inadimplentes (recall 0,18).
- **Assimetria e outliers** (skew de até 30, 8–10% de outliers): explicam por que as técnicas diferem entre si, já que cada uma reage de forma diferente aos valores extremos.
- **Desbalanceamento (77,88% / 22,12%)**: explica por que a acurácia sobe pouco, pois o baseline já é alto, e por que o recall continua baixo mesmo com normalização (o voto dos vizinhos é dominado pela classe que paga).

Questão 2

5. Existe evidência de que o dataset pode ser usado sem normalização? Não, os dados indicam o contrário. Sem normalização a acurácia (0,7552) ficou **abaixo do baseline** (0,7788), em 2,36 p.p., ou seja, o modelo é pior do que simplesmente prever “pagou” para todos. Já as três versões normalizadas ficaram acima do baseline. Além disso, o recall da classe 1 é metade do obtido com normalização.

6. A diferença é suficiente para afirmar que uma configuração é claramente superior? Depende da comparação (margem de erro: $\pm 1,02$ p.p.):

- **Sem normalização contra as demais:** sim, claramente pior, com diferenças de 3,00 a 4,17 p.p., bem acima da margem.
- **Entre as três técnicas normalizadas:** não de forma conclusiva. Standard contra MinMax difere em apenas 0,35 p.p. (dentro da margem); MinMax contra logarítmica, 0,82 p.p. (dentro da margem); Standard contra logarítmica, 1,17 p.p., só um pouco acima da margem. Como foi usado um único split, é um indício, não uma prova.

7. Por que as técnicas dão resultados diferentes? O KNN decide pelo voto dos K vizinhos mais próximos, e “próximo” depende só da distância euclidiana. Cada técnica muda a geometria do espaço de forma diferente: o MinMax limita cada variável a [0, 1], mas depende do mínimo e do máximo (sensíveis a outliers); o Standard centraliza e divide pelo desvio padrão, dando peso comparável a cada variável; a logarítmica comprime os valores grandes, mas mantém as escalas ainda desiguais. Com distâncias diferentes, mudam os vizinhos de cada cliente, o resultado da votação e a classe prevista.

Conclusão (solução final): Adota-se a **configuração 3 – StandardScaler**, que teve a maior acurácia de validação (0,7969), o melhor recall (0,3462) e o melhor F1 (0,4300), avaliada sob as mesmas condições das demais.


Questão 3

Técnica usada: StandardScaler. Alguns pontos da tabela completa (21 valores de K)

K	Treinamento	Validação	Diferença (treino – validação)
1	0,9996	0,7340	26,6 p.p.
3	0,8662	0,7751	9,1 p.p.
5	0,8410	0,7969	4,4 p.p.
15	0,8246	0,8114	1,3 p.p.
31	0,8172	0,8139	0,3 p.p.
41	0,8172	0,8123	0,5 p.p.

Questão 3

KNN: acurácia em função de K (StandardScaler (z-score))



Questão 3

1. Qual K teve a maior acurácia de validação? K = 31, com 0,8139.

2. Deve ser escolhido automaticamente? Não. O erro-padrão é de $\approx 0,0050$, e todos os K de 15 a 41 ficaram dentro dessa faixa do melhor (acurácia de validação entre 0,8106 e 0,8139). A diferença entre eles é menor que 0,35 p.p., ou seja, é ruído. Por isso a escolha deve considerar outros critérios, como a estabilidade e a distância entre treino e validação.

3. O que acontece quando K é muito pequeno? O modelo decide com pouquíssimos vizinhos e copia o ruído e os outliers. Com K = 1 a acurácia de treino é 0,9996 (cada ponto é vizinho dele mesmo), mas a de validação é só 0,7340, **abaixo do baseline** (0,7788). É o **sobreajuste (overfitting)**: ele decora o treino e generaliza mal.

4. O que acontece quando K é muito grande? O voto passa a refletir a proporção geral das classes, dominada pelos 78% que pagam. O modelo fica cada vez mais simples e tende a prever sempre “pagou”, aproximando-se do baseline, e o recall da classe 1 cai. É o **subajuste (underfitting)**. Neste experimento, porém, K foi testado só até 41, e nessa faixa ainda **não há queda visível**; para observar o subajuste claramente seria preciso testar valores bem maiores (centenas).

5. O gráfico mostra sobreajuste ou subajuste?

- **Sobreajuste (overfitting): sim, em K pequeno.** A linha de treino (0,9996) está muito acima da de validação (0,7340) em K = 1, uma diferença de 26,6 p.p. Essa diferença cai rapidamente (9,1 p.p. em K = 3, 4,4 p.p. em K = 5) até quase desaparecer.
- **Subajuste (underfitting): não há indício claro até K = 41.** A validação sobe até K ≈ 15 e depois se estabiliza em torno de 0,813, sem cair, e as duas linhas se aproximam (0,8172 / 0,8123).

Questão 3

6. Qual K é mais adequado? K = 41, escolhido pela regra do erro-padrão (o maior K dentro de 1 erro-padrão do melhor). Sua acurácia de validação (0,8123) é equivalente à melhor (0,8139, diferença de 0,16 p.p.), e a distância entre treino e validação é pequena (0,5 p.p.), o que indica boa capacidade de generalização, com um modelo mais suave e estável. Duas ressalvas honestas: K = 31 (o de maior validação) seria uma escolha igualmente defensável, e K = 41 está no limite superior da faixa testada.

Modelo final no conjunto de teste: treinado com treino + validação, usando StandardScaler e K = 41, o modelo obteve **acurácia de 0,8114 no teste**, praticamente igual à de validação (0,8123, diferença de 0,09 p.p.), o que confirma que generaliza bem. Fica 3,26 p.p. acima do baseline (0,7788). No entanto, o **recall da classe 1 foi de apenas 0,3258** (F1 = 0,4333): o modelo acerta bem quem paga, mas encontra só cerca de um terço dos inadimplentes. Isso mostra que a acurácia sozinha é uma medida limitada em dados desbalanceados.