UNIVERSIDADE FEDERAL DO CEARÁ

# TECHNICAL REPORT

Alunos: Francisco de Paula Mesquita Júnior e Natércia de Sousa Félix

## 1. Introdução

*Este relatório técnico aborda a análise de dois datasets distintos, explorando suas características principais e objetivos de análise.*

***Dataset 1: Prever diabetes***

*O dataset utilizado contém informações clínicas e demográficas de indivíduos, com foco em variáveis relevantes para a avaliação do risco de diabetes. Ele inclui as seguintes variáveis:*

- ***Gravidezes**: Quantidade de gestações da paciente.*
- ***Glicose**: Concentração de glicose no sangue.*
- ***Pressão Arterial**: Valor da pressão arterial sistólica.*
- ***Espessura da Pele**: Espessura da dobra cutânea em milímetros.*
- ***Insulina**: Quantidade de insulina presente no sangue.*
- ***IMC**: Índice de Massa Corporal, indicando a relação entre peso e altura.*
- ***Função Pedigree de Diabetes**: Indicador de risco genético para diabetes.*
- ***Idade**: Idade dos participantes.*
- ***Resultado**: Diagnóstico de diabetes, sendo 1 para positivo e 0 para negativo.*

***Objetivos da Análise***

- *Investigar como cada variável está relacionada ao diagnóstico de diabetes.*
- *Desenvolver um modelo preditivo eficiente para identificação de pacientes em risco.*
- *Fornecer informações que possam orientar medidas preventivas e estratégias de intervenção voltadas ao controle do diabetes.*

***Dataset 2: Vendas de casas em King County, EUA***

*Este conjunto de dados contém os preços de venda de casas para King County, que inclui Seattle. Inclui casas vendidas entre maio de 2014 e maio de 2015.*

***Variáveis Principais***

- ***Preço**: Valor da transação imobiliária.*
- ***Número de Quartos e Banheiros**: Infraestrutura do imóvel.*
- ***Área Habitável e do Terreno**: Medidas em pés quadrados.*
- ***Condição e Avaliação**: Qualidade e estado da propriedade.*
- ***Ano de Construção e Reforma**: Idade e modernidade do imóvel.*
- ***Localização Geográfica**: Coordenadas e CEP.*

***Objetivos da Análise***

- *Identificar os fatores que mais influenciam o preço.*
- *Criar um modelo preditivo robusto para estimar os preços de novas propriedades, utilizando técnicas como regressão linear e regularização.*
-

## 2. Observações

## 3. Resultados e discussão

***Questão 1** - Essa questão tem como objetivo realizar a manipulação em um dataset com a biblioteca pandas e realizar o pré-processamento. A seguir um fluxograma do processo:*

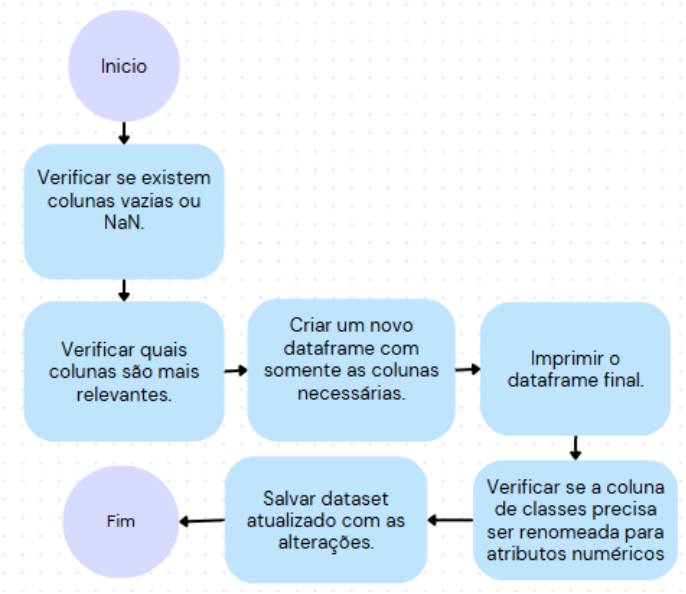


*[Figura 1- Fluxograma do Processo].*

***Exploração Inicial do Dataset***

*Foi realizada uma inspeção no dataset após o processo de limpeza e ajustes. A Figura 2 apresenta as cinco primeiras entradas do dataset final, destacando as principais variáveis clínicas e demográficas utilizadas na análise.*

| Gravidezes | Glicose | Pressão Arterial | Espessura da Pele | Insulina | IMC | Função Pedigree | Idade | Classe |
|---|---|---|---|---|---|---|---|---|
| 6 | 148 | 72 | 35 | 0 | 33.6 | 0.627 | 50 | 1 |
| 1 | 85 | 66 | 29 | 0 | 26.6 | 0.351 | 31 | 0 |
| 8 | 183 | 64 | 0 | 0 | 23.3 | 0.672 | 32 | 1 |
| 1 | 89 | 66 | 23 | 94 | 28.1 | 0.167 | 21 | 0 |
| 0 | 137 | 40 | 35 | 168 | 43.1 | 2.288 | 33 | 1 |

*[Figura 2- Amostra do Dataset Final].*

*A Figura 3 abaixo apresenta a quantidade de registros para cada classe, evidenciando a proporção de diagnósticos positivos e negativos de diabetes no conjunto de dados.*

| Classe | Quantidade | Percentual |
|---|---|---|
| 0 (Não Diabético) | 500 | 65.1% |
| 1 (Diabético) | 268 | 34.9% |

*[Figura 3 -Distribuição de Classes no Dataset Final].*

***Questão 2 -*** *Nessa etapa, implementamos e avaliamos o desempenho do algoritmo KNN (K-Nearest Neighbors) utilizando diferentes métricas de distância. As métricas consideradas foram:*

- *Mahalanobis*
- *Chebyshev*
- *Manhattan*
- *Euclidean*

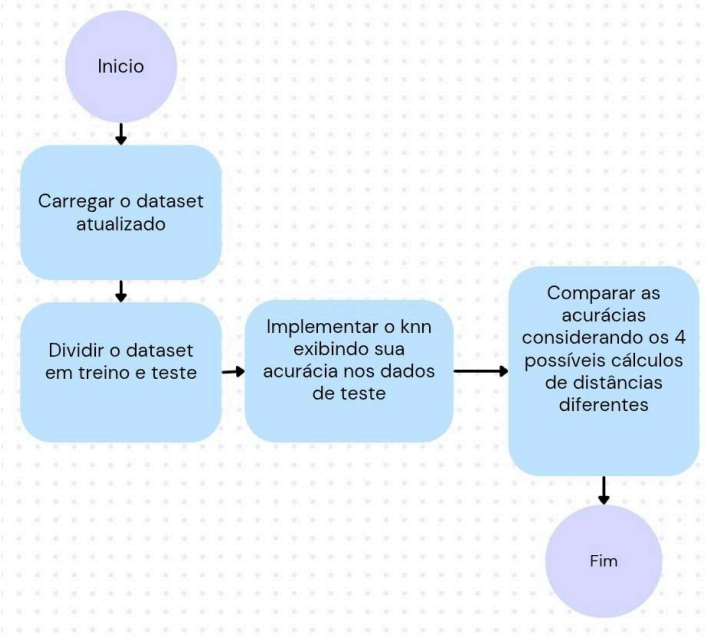


*[Figura 4- Fluxograma do Processo].*

***Resultados Obtidos***

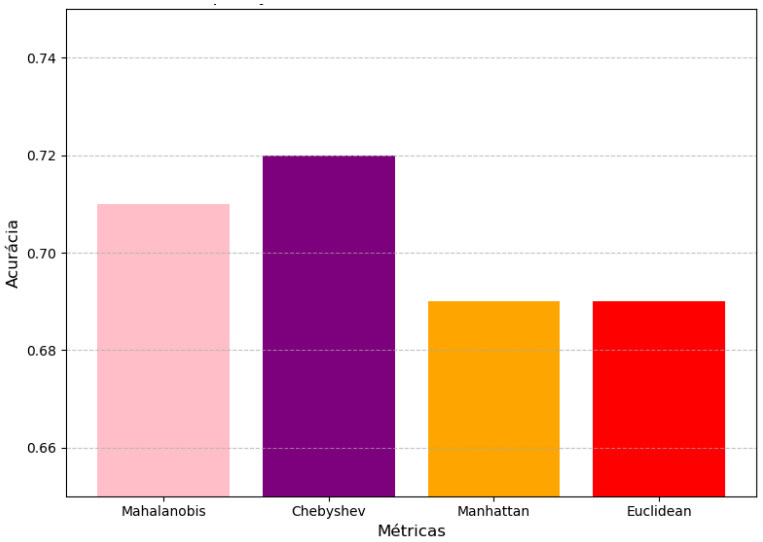


*[Figura 5 -Comparação de Aucárias com Diferentes Métricas].*

- ***Mahalanobis**: Considera a correlação entre as variáveis, ajustando as distâncias de acordo com a dispersão dos dados.*

- ***Chebyshev**: Mede a maior diferença absoluta entre duas coordenadas.*
- ***Manhattan**: Soma as diferenças absolutas em cada dimensão.*
- ***Euclidean**: Representa a distância reta em um espaço multidimensional.*

***Resultados e Conclusão***

*A métrica Chebyshev apresentou o melhor desempenho, com acurácia de 0.71, enquanto a Mahalanobis teve o pior, com 0.63. Isso sugere que métricas mais simples podem ser mais robustas para este conjunto de dados.*

***Questão 3 -** Nesta análise, buscamos avaliar como diferentes métodos de normalização dos dados afetam o desempenho do KNN. Considerando que o algoritmo é baseado em distância, a escala das variáveis pode influenciar diretamente os resultados.*

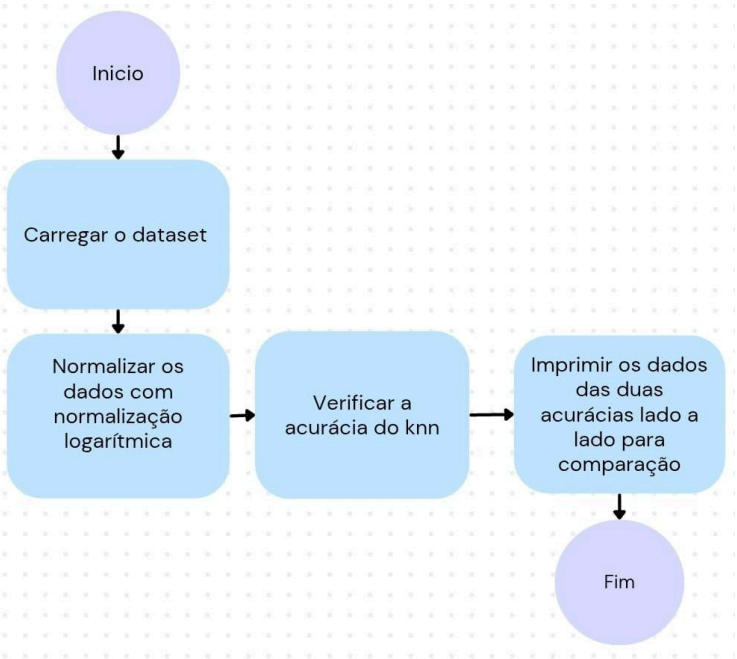


*[Figura 6 - Fluxograma do Processo].*

*Utilizamos a métrica Chebyshev, previamente identificada como a mais eficaz, para testar os seguintes métodos de normalização:*

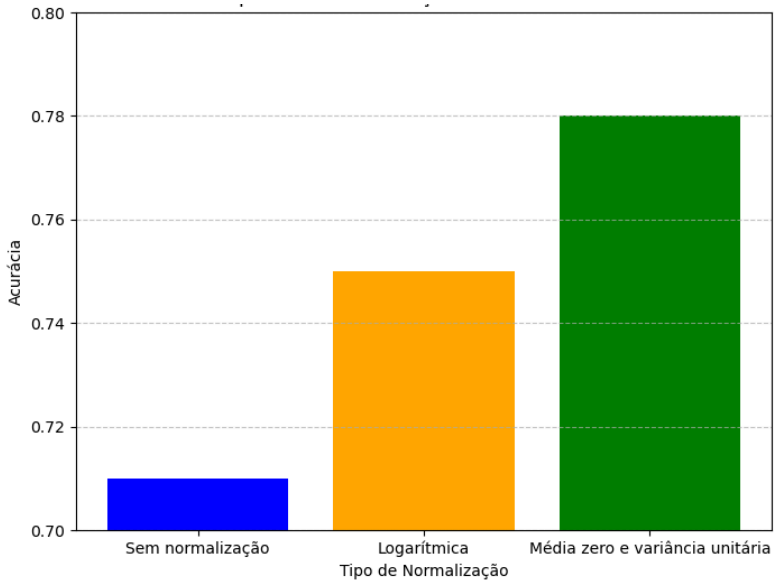


*[Figura 7 -Inpacto da Normalização nos Dados no KNN].*

***Resultados e Conclusão***

*A normalização de média zero e variância unitária obteve a melhor acurácia (0.78), demonstrando a importância de ajustar a escala dos dados. A transformação logarítmica também foi útil (0.75), enquanto a ausência de normalização limitou os resultados.*

***Questão 4 -*** *Avaliamos o impacto do número de vizinhos () no desempenho do KNN, com o objetivo de encontrar o valor de que maximize a acurácia do modelo.*

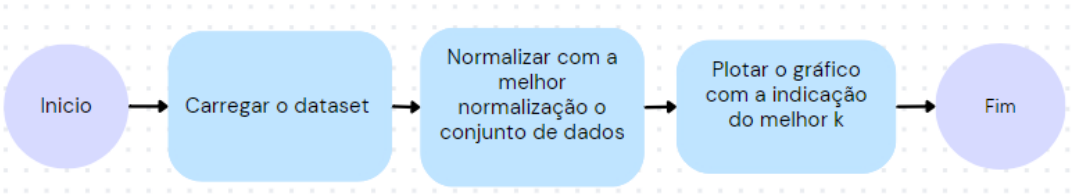


*[Figura 8 - Fluxograma do Processo].*

***Resultados Obtidos***

*Testamos valores de variando de 1 a 20. O melhor resultado foi obtido com k = 15, alcançando uma acurácia de 0.69.*

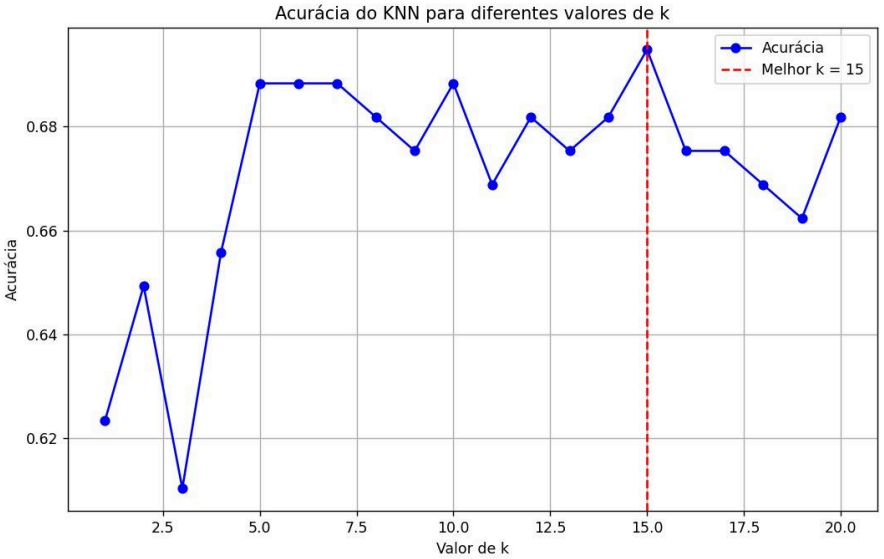


*[Figura 9 -Grafico de Comparação].*

***Resultados e Conclusão***

*O melhor desempenho foi com k = 15, alcançando uma acurácia de 0.69. Valores menores de k tornaram o modelo sensível a ruídos, enquanto valores maiores reduziram a capacidade de capturar padrões locais.*

***Questão 5 -*** *Preparar o dataset KC House para análises subsequentes, identificando os atributos mais correlacionados ao preço dos imóveis e salvando o conjunto de dados processado.*

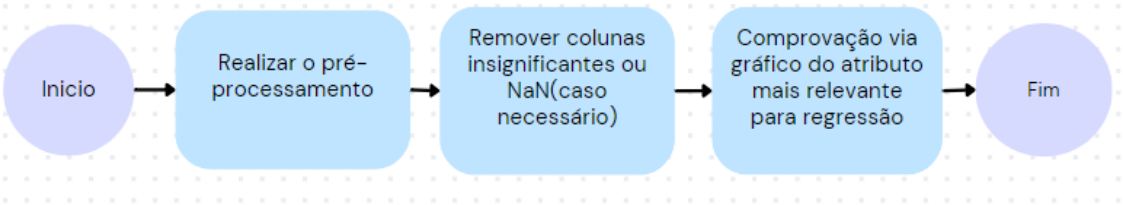


*[Figura 10 - Fluxograma do Processo].*

***Resultados Obtidos***

*Os seguintes atributos apresentaram maior correlação com o preço dos imóveis:*

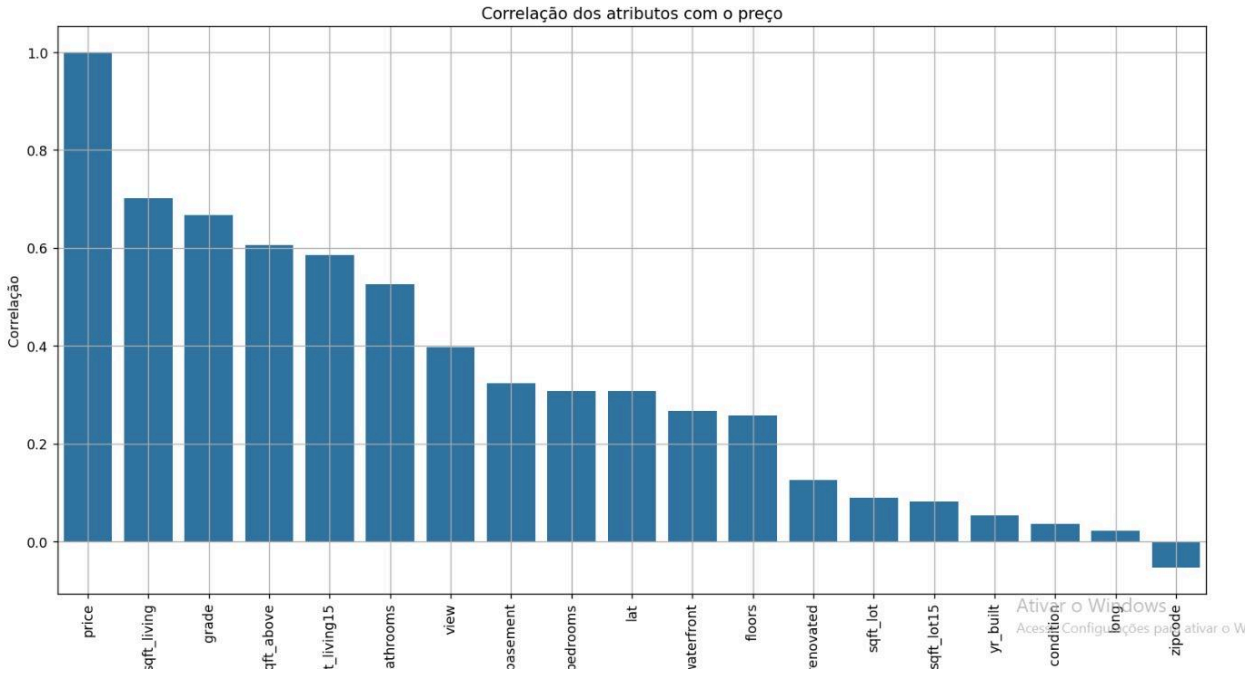


*[Figura 11 -Grafico de Correlação].*

- ***Seleção de Atributos****: Utilizamos a matriz de correlação para medir o grau de associação linear entre as variáveis. Apenas atributos com correlação significativa foram mantidos para análises posteriores.*
- ***Tratamento de Dados****:*
  - *Valores ausentes foram preenchidos ou removidos.*
  - *Variáveis categóricas foram codificadas (se necessário).*
  - *Escalas dos atributos foram analisadas, considerando normalizações futuras.*

***Benefícios dos Atributos Selecionados***

*Os cinco atributos selecionados para análise posterior possuem interpretações claras:*

- ***sqft_living****: Reflete o tamanho da área habitável da casa.*
- ***grade****: Representa a qualidade geral do imóvel, conforme avaliada por peritos.*

- ***sqft_above*** *e* ***sqft_living15****: Ajudam a capturar informações adicionais sobre o tamanho do imóvel.*
- ***bathrooms****: Está relacionado ao conforto e utilidade da casa.*

***Questão 6 -*** *Nesta etapa, desenvolvemos um modelo de regressão linear simples com foco em prever os preços dos imóveis com base no atributo de maior correlação, sqft_living. Este modelo ajuda a entender como o tamanho da área habitável influencia diretamente no preço.*

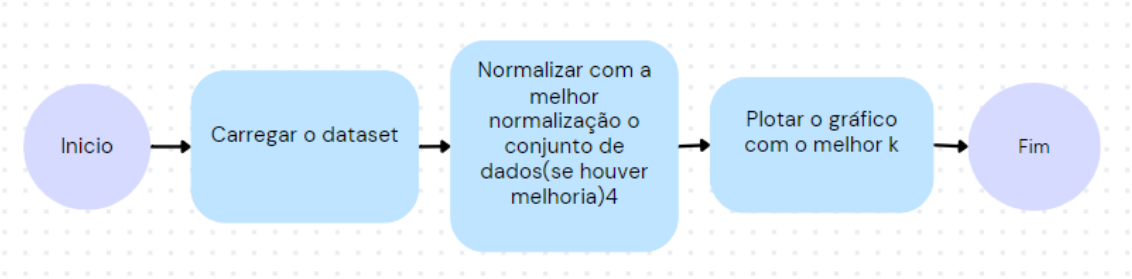


*[Figura 12 - Fluxograma do Processo].*

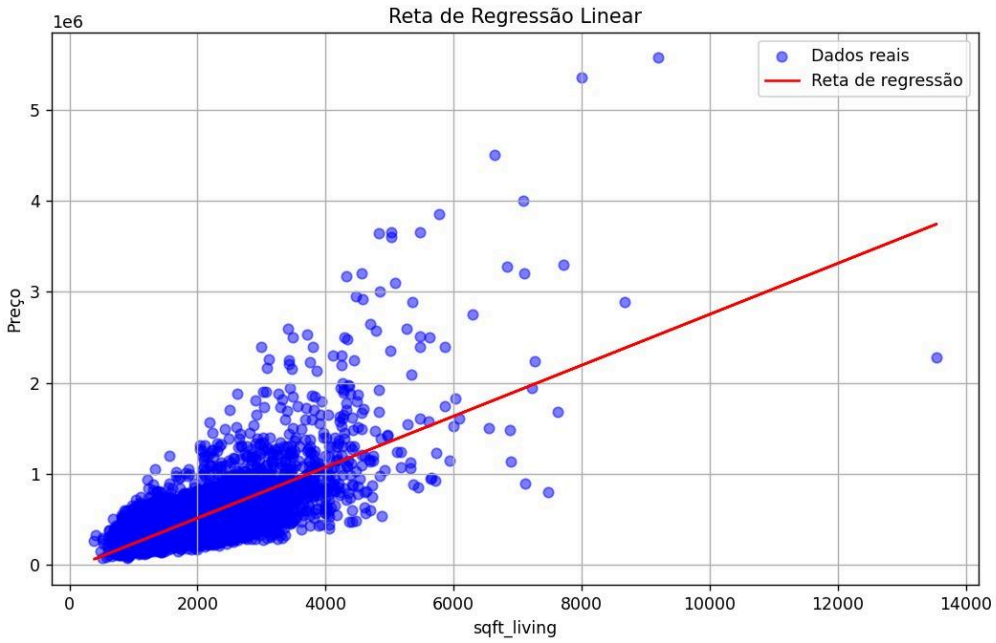

***Interpretação da Reta de Regressão**:*

- *O coeficiente angular indica quanto o preço do imóvel aumenta em média para cada unidade adicional de **sqft_living**.*
- *O intercepto reflete o preço base estimado para um imóvel com área habitável zero (usado apenas para fins interpretativos).*

***Resultados e Conclusão***

*O modelo alcançou um $R^2$ de 0.65, indicando que a variável sqft_living explica uma parte significativa da variação no preço dos imóveis, mas ainda há espaço para melhorias.*

***Questão 7 -** Comparar os modelos de regressão (Linear, Ridge e Lasso) utilizando validação cruzada para identificar o modelo mais eficaz.*

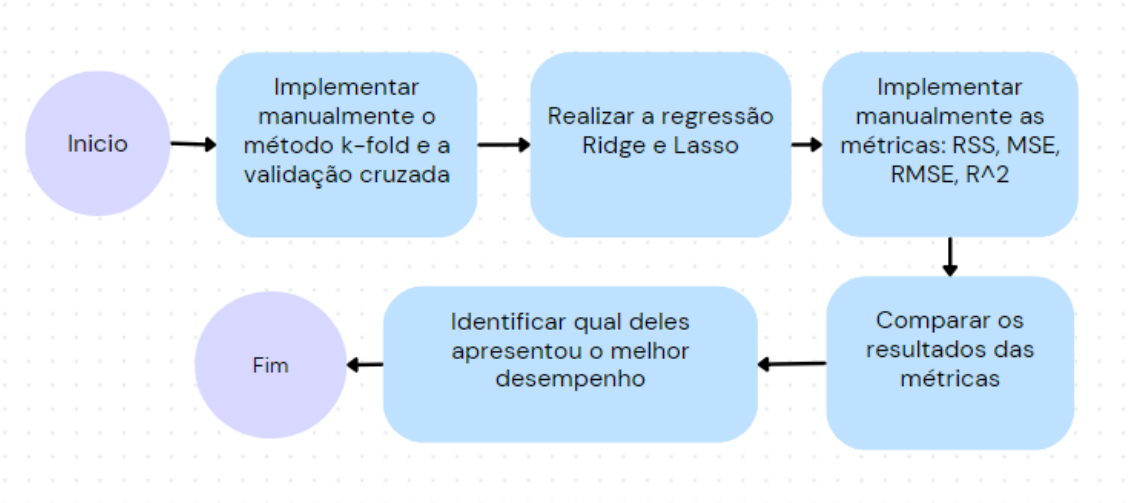


*[Figura 13 - Fluxograma do Processo].*

***Divisão do Dataset:** O dataset foi dividido em k subconjuntos de tamanho aproximadamente igual.*

***Treinamento e Avaliação:***

- *Em cada iteração, um dos k subconjuntos foi reservado para validação (conjunto de teste), enquanto os k-1 restantes foram usados para treinar o modelo.*
- *O desempenho foi avaliado em cada iteração usando métricas como RSS, MSE, RMSE e R2R^2R2.*

***Média das Métricas:*** *Após realizar todas as iterações, as métricas foram calculadas como a média dos resultados obtidos em cada uma das partições, garantindo uma avaliação mais robusta e confiável do desempenho de cada modelo.*

***Resultados e Conclusão***

*O modelo Ridge foi o mais eficaz, com maior $R^2$ (0.65) e menores erros. O Lasso apresentou o pior desempenho, provavelmente devido à penalização excessiva dos coeficientes.*

## 4. Conclusões

*Os resultados esperados foram, em grande parte, atendidos, embora existam áreas para melhorias. No caso do dataset de diabetes, foi identificado que a métrica de distância Chebyshev apresentou melhor desempenho no modelo KNN, especialmente quando combinado com normalização apropriada, alcançando uma acurácia de 0.78. Já no dataset de vendas de imóveis, o modelo de regressão linear simples indicou uma forte influência do atributo "sqft_living" no preço das propriedades, com um $R^2$ de 0.65. Apesar disso, o uso de modelos mais avançados, como Ridge, mostrou resultados mais robustos.*

*A principal análise é que ajustes na seleção de variáveis, normalização e escolha de modelos podem aumentar a eficácia preditiva e a capacidade de interpretação.*

## 5. Próximos passos

**Dataset de Diabetes:**

- *Investigar o impacto de outros algoritmos de classificação, como Random Forest e Gradient Boosting, para comparar com o KNN.*
- *Explorar técnicas de feature engineering para criar variáveis mais representativas.*

- *Implementar análises preditivas com validação cruzada para aumentar a confiabilidade dos modelos.*

**Dataset de Imóveis:**

- *Ampliar os estudos com regressão múltipla incorporando mais atributos significativos identificados pela matriz de correlação.*
- *Explorar modelos mais sofisticados, como Random Forest Regressor ou XGBoost, para capturar melhor a não-linearidade nos dados.*
- *Realizar tuning de hiperparâmetros nos modelos Ridge e Lasso para minimizar erros.*

**Geral:**

- *Documentar as decisões tomadas para garantir reprodutibilidade e facilitar futuras análises.*
- *Publicar os resultados em uma plataforma ou relatório interativo para maior acessibilidade e utilidade prática.*