UNIVERSIDADE FEDERAL DO CEARÁ

TECHNICAL REPORT

Aluno: Aryely Maria Silva Matos e Carlos Adriel Sousa Bastos

1. Introdução

Dataset de Classificação:

O dataset usado para a análise de classificação apresenta dados referentes às características de pacientes diagnosticados com câncer. Cada conjunto de dados contém um ID exclusivo que caracteriza cada paciente, contém o tipo de câncer - se é Maligno ou Benigno e características visuais do câncer.

As principais features do dataset são:

- **Diagnóstico:** Indica o tipo de câncer, que tem como valores M - Maligno e B - Benigno
- **concave points_worst:** Refere-se ao maior número de pontos côncavos detectados nas bordas do tumor na imagem digitalizada.
- **radius_worst:** Representa o maior valor do raio do tumor entre todas as medições feitas.

2. Observações

Quando implementamos o KNN com ***GridsearchCV*** não conseguimos calcular a distância Mahalanobis, pois a mesma não existe no GridsearchCV.

3. Resultados e discussão

Questão 1:

Nessa questão, primeiramente fazemos o carregamento dos dados com a leitura do CSV, contendo os dados com as informações do dataset de câncer. Logo após fazemos o pré-processamento removendo as colunas relevantes, que no caso são *Unnamed* que contém NaN e ID que é apenas um identificador. Logo após convertemos a variável alvo *diagnosis* para valores numéricos M=1 e B=0. Por fim, para melhor desempenho substituimos os valores infinitos por NaN e removemos as linhas com valores ausentes. Após o fim do pré-processamento iniciamos a normalização dos dados, usamos o *StandardScaler* para padronizar os atributos e dividimos o conjunto de dados, separamos em treino (70%) e teste (30%). Depois dessa divisão fizemos a avaliação do modelo. Aplicamos as predições no conjunto de teste, cálculo da acurácia e a construção da matriz de confusão para a análise dos erros. Em relação a implementação os dados foram carregados a partir do arquivo *Cancer_Data.csv.* A

remoção das colunas sem relevância para a análise melhoram o processamento e treinamento do modelo. Sendo assim, afirmamos que o pré-processamento foi feito com sucesso. Logo após, a normalização foi realizada com o StandardScaler garantindo que as features tivessem média 0 e desvio padrão 1. O modelo do KNN foi ajustado utilizando GridSearchCV para encontrar a melhor combinação de parâmetros (n_neighbors - quantidade de K e metric - distâncias a serem calculadas) O modelo foi avaliado com base na acurácia dos conjuntos de validação cruzada e também através de uma matriz de confusão para a visualização dos erros de classificação.

Tabela 1 - Comparação da questão de implementação da AV1 e a AV2 utilizando K=7:

Distância	Número de vizinhos	Acurácia (AV1)	Acurácia (AV2)
Euclidean	7	0.9646	0.9597
Manhattan	7	0.9734	0.9547
Chebyshev	7	0.9557	0.9321

Tabela 2 - Tabela com o melhor valor de K e melhor distância com o uso do GridsearchCV

GridSearchCV		
Distância	**Número de vizinhos**	**Acurácia**
Manhattan	3	0.97076

Gráfico 1 - Matriz de confusão (visualização dos erros e acertos do modelo)

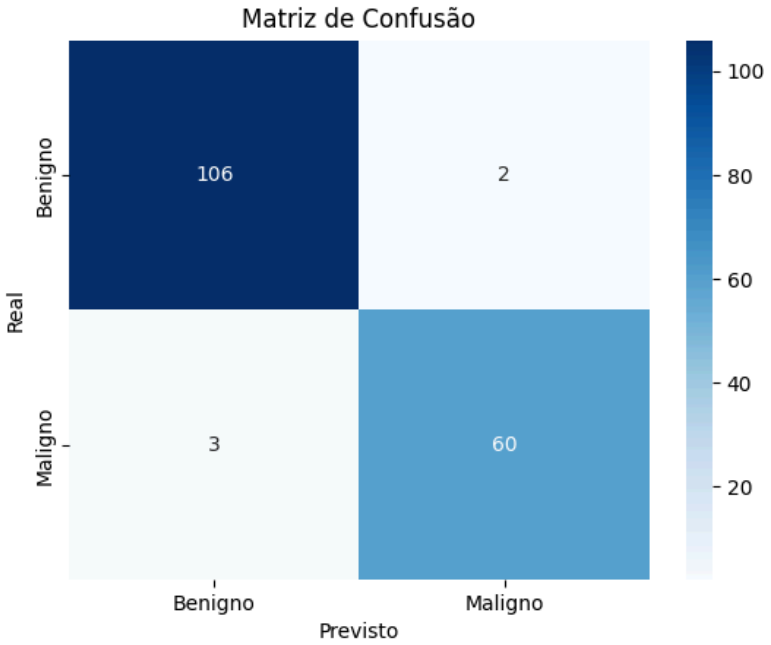

- **Falsos Positivos** – 2 casos: O modelo classificou erroneamente casos benignos como malignos, ou seja, pacientes sem a condição foram indicados como doentes.

- **Falsos Negativos** – 3 casos: O modelo classificou erroneamente casos malignos como benignos, ou seja, pacientes com a condição não foram identificados corretamente.

Questão 2:

Nesta questão carregamos o conjunto de dados a partir de um arquivo CSV e fazemos um pré-processamento que inclui a remoção de colunas irrelevantes (Unnamed: 32, id), conversão da variável diagnosis para valores binários (M para 1 e B para 0), tratamento de valores infinitos e remoção de valores ausentes. As features foram padronizadas com StandardScaler, e os dados foram divididos em treino e teste (70/30). Para otimizar o modelo KNN, o GridSearchCV foi utilizado para testar diferentes hiperparâmetros, selecionando os melhores parâmetros, calculando a acurácia e gerando uma matriz de confusão, que indicou um bom desempenho na classificação entre tumores malignos e benignos. O melhor conjunto de parâmetros encontrados foi n neighbors=n e metric=*Euclidean, Manhattan e Chebyshev*, com uma

acurácia de 97%. No agrupamento com *K-Means*, o mesmo conjunto de dados foi carregado, removendo-se as colunas irrelevantes (*Unnamed: 32, id, diagnosis*) e aplicando a normalização com *StandardScaler*. O número ótimo de clusters foi determinado pelo método do cotovelo, analisando a inércia para diferentes valores de k, e pelo método da silhueta, que avaliou a qualidade dos agrupamentos. O treinamento do modelo foi realizado executando o algoritmo *K-Means* para diferentes valores de k, garantindo uma melhor estruturação dos agrupamentos nos dados.

Gráfico 2 - Método de Cotovelo

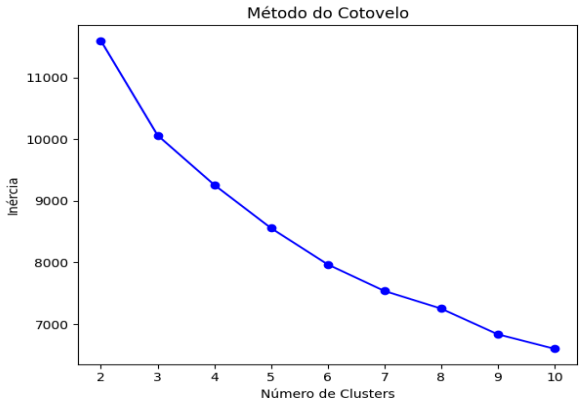

Gráfico 3 - Método de Silhueta

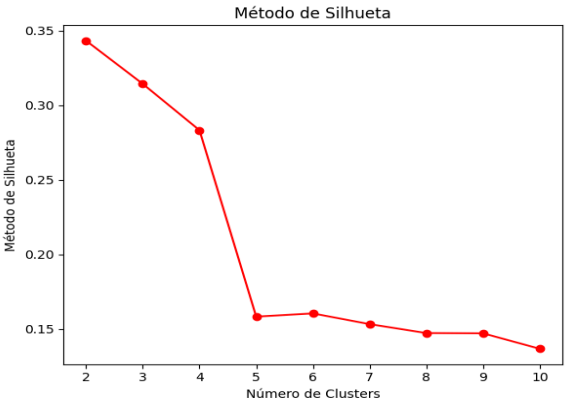

- Com base no que foi estudado na disciplina, podemos observar nas imagens que a melhor quantidade de clusters usando o método do cotovelo é 3 ou 4, pois ainda está estável enquanto no método de silhueta a melhor quantidade de clusters é 2, pois é o ponto mais alto do gráfico.

Questão 3:

Para a resolução dessa questão, inicialmente utilizamos o método Lasso para termos conhecimento sobre os dois melhores atributos do dataset e assim identificamos os atributos "**concave points_worst**" e "**cradius_worst**" como os mais relevantes. Logo após, aplicando os atributos retornados pelo método Lasso aos métodos de Cotovelo e Silhueta, conseguimos visualizar qual seria a melhor quantidade de clusters para o dataset.

Gráfico 2 - Método de Cotovelo com os dois atributos mais importantes

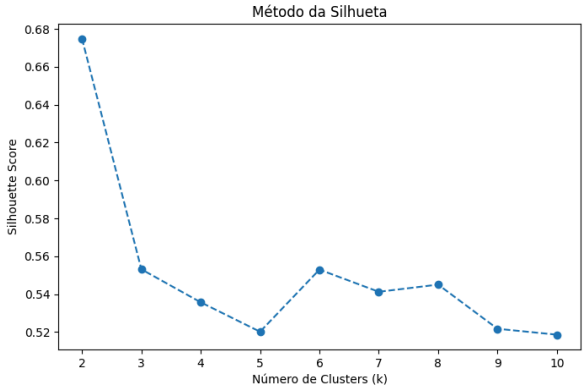

Gráfico 3 - Método de Silhueta com os dois atributos mais importantes

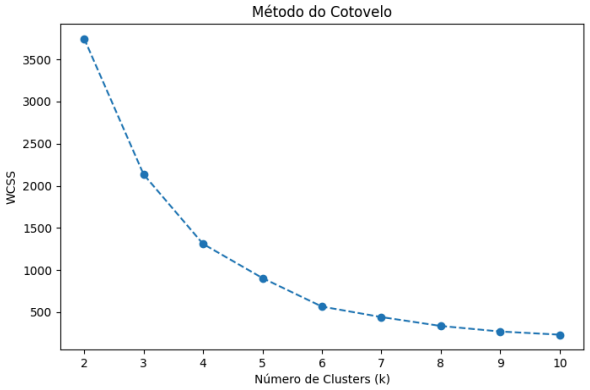

No gráfico de cotovelo é possível ver que a partir do eixo X = 4, a linha começa ter um menor índice de variância, com isso, podemos identificar que esse gráfico nos diz que o melhor valor para a clusterização seria 4.

Quanto ao gráfico de silhueta, o ponto mais alto mostrado é o eixo X = 2, que significa que o melhor valor para a clusterização seria 2, o que faz muito sentido já que nossa variável alvo possui valores binário, podendo ser ”Benigno” ou “Maligno”.

Em comparação com o resultado obtido nos métodos de Cotovelo e Silhueta na questão anterior, podemos perceber que os valores retornados pelos gráficos se mantêm. Assim, não necessitamos de implementar os scatterplots.

Questão 4:

Por fim, nessa questão tivemos que analisar como fica a distribuição de clusters. Para isso, fizemos um crosstab utilizando o KMeans com o valor de k = 2, valor determinado pelo resultado do método de Silhueta da questão anterior.

Tabela 3 - Análise dos clusters

Varieties/ /Labels	0	1
0	356	82
1	1	130

A partir da tabela conseguimos ver a distribuição dos clusters. No cluster 0 é possível ver uma grande concentração de câncer benigno em comparação ao câncer

maligno. Mas, apesar de ter uma grande diferença entre os números apresentados no cluster 0, o número de câncer maligno não é totalmente irrelevante já que é considerado um número um tanto alto em comparação com o total. Já no cluster 1 conseguimos ver que há uma concentração no tipo de câncer maligno, e que neste cluster a separação das variáveis foi muito efetiva.

4. Conclusões

Acreditamos que os resultados obtidos foram totalmente satisfatórios. Observamos uma notável evolução pessoal desde a última avaliação, e desta vez conseguimos alcançar todos os objetivos da avaliação com êxito.

5. Próximos passos

*A*creditamos que seria uma boa melhoramos o modelo (seja utilizando outras métricas, ferramentas e etc.) para refinar ainda mais os resultados expostos aqui. Dessa forma, a matriz de confusão que já foi muito bem implementada (ficou 5 erros) ficaria melhor ainda - com uma taxa de erros ainda menor. Isso mostraria um modelo bem treinado, feito esse importantíssimo para alcançar o objetivo da disciplina.