UNIVERSIDADE FEDERAL DO CEARÁ - CAMPUS ITAPAJÉ
CURSO DE TECNOLOGIA EM SEGURANÇA DA INFORMAÇÃO
INTELIGÊNCIA ARTIFICIAL - PROFESSOR ALYSON BEZERRA
MIZAEL CASTRO GOMES
GLAUBER DE MELO DUARTE

TECHNICAL REPORT

INTRODUÇÃO

Este relatório apresenta uma análise detalhada do dataset "Drug Classification", disponível no Kaggle, que tem como objetivo principal classificar o tipo de medicamento prescrito com base em características dos pacientes. O conjunto de dados inclui o seguinte:

Variável Alvo:

- Tipo de Medicamento (*Drug*): Representa o medicamento prescrito (DrugY, drugC, drugX, drugA).

Atributos(*Features*):

- Idade (*Age*): Idade do paciente.
- Sexo (*Sex*): Gênero do paciente.
- Pressão Arterial (*BP*): Níveis categorizados como HIGH, LOW ou NORMAL.
- Colesterol (*Cholesterol*): Níveis categorizados como HIGH ou NORMAL.
- Relação Sódio-Potássio (*Na to K*): Proporção entre sódio e potássio.

A partir desse contexto, foram realizadas **quatro análises principais:**

1. Otimização dos parâmetros do modelo *KNN* utilizando *GridSearchCV* para avaliar sua performance na classificação;
2. Determinação da quantidade ideal de *clusters* no dataset por meio dos métodos do cotovelo e da silhueta;
3. Seleção dos atributos mais relevantes utilizando *Lasso* e reavaliação da quantidade de *clusters*; e
4. Análise da distribuição dos *clusters* em relação à coluna alvo através de um *crosstab*.

Este relatório tem como objetivo não apenas explorar as características do dataset, mas também identificar padrões que ajudem a compreender como os atributos dos pacientes estão relacionados aos medicamentos prescritos.

OBSERVAÇÕES

Nas questões 2, 3 e 4, foram observadas discrepâncias nos resultados gerados pelos códigos em diferentes máquinas. Na máquina do Glauber, ao executar as questões 2 e 3, o gráfico exibiu um resultado específico, enquanto na máquina do Mizael, os resultados foram diferentes. Além disso,

na questão 4, que solicitava uma tabela cruzada (cross-tab), os resultados também foram fixos e variaram entre as duas máquinas, apresentando valores distintos. Segue as imagens comprovando as discrepâncias abaixo:

Discrepâncias da Questão 2 - Método do Cotovelo

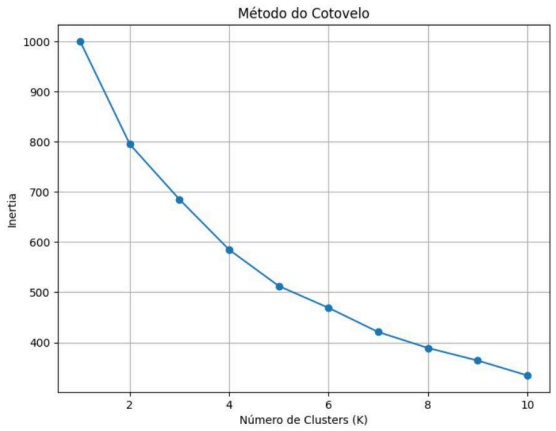

Máquina do Mizael

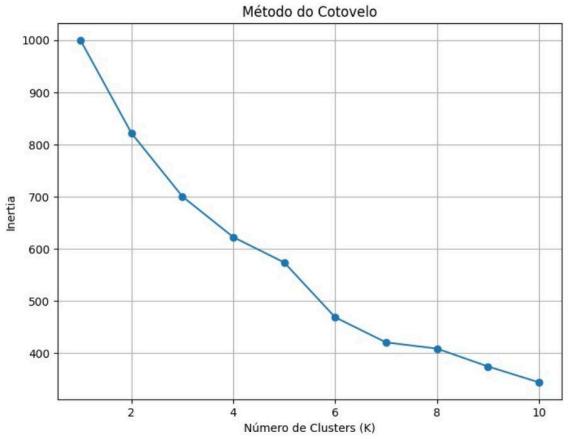

Máquina do Glauber

Discrepâncias da Questão 2 - Método da Silhueta

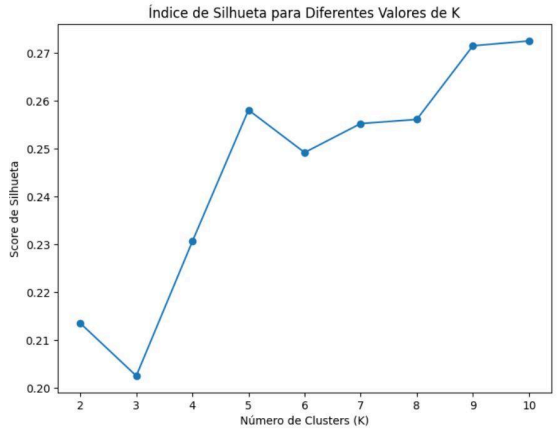

Máquina do Mizael

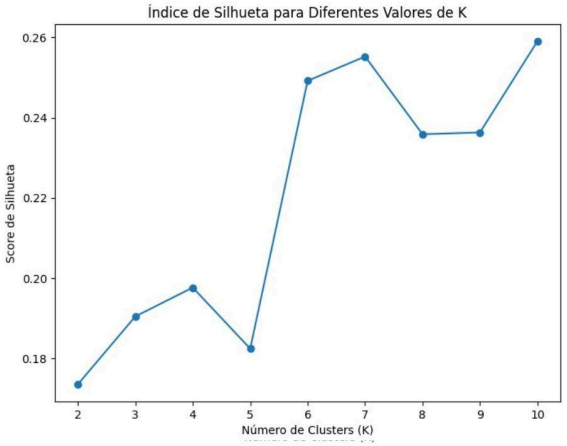

Máquina do Glauber

Discrepância da Questão 3 - Método do Cotovelo

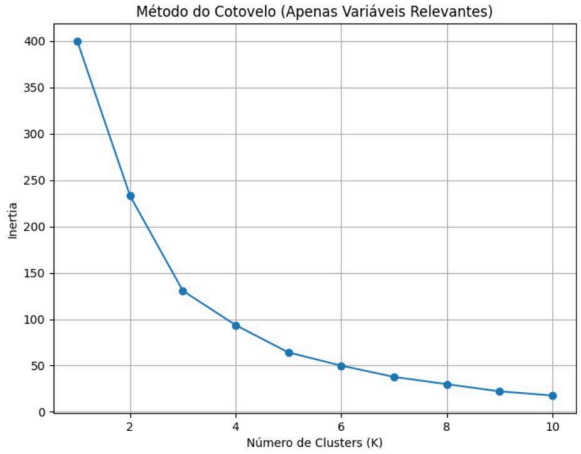

Máquina do Mizael

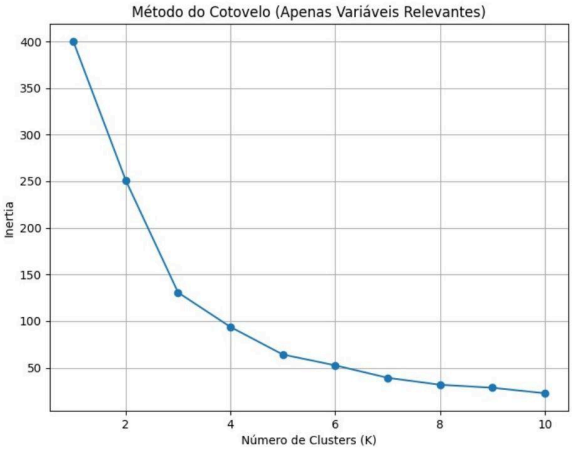

Máquina do Glauber

Discrepância da Questão 3 - Método da Silhueta

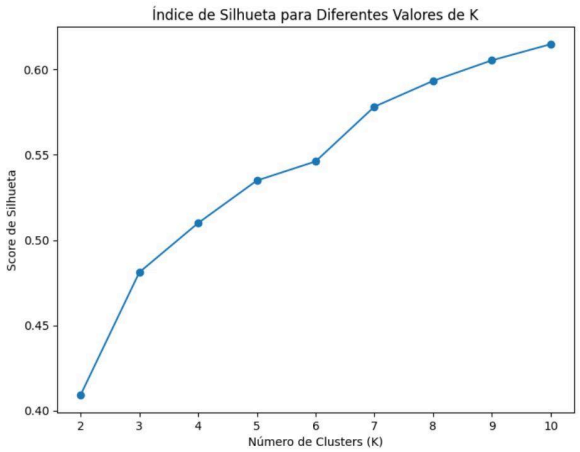

Máquina do Mizael

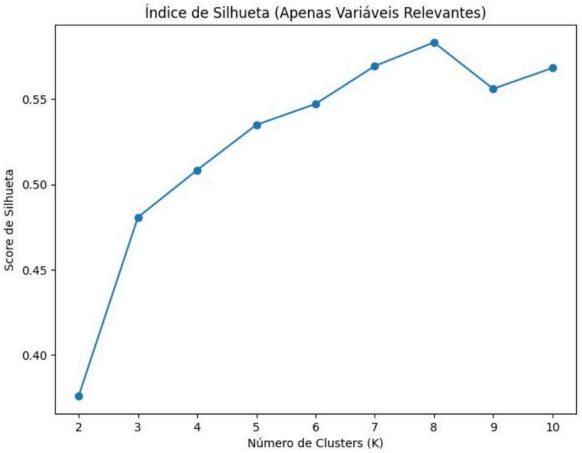

Máquina do Glauber

Discrepância da Questão 3 - Métricas em Lasso da Importância das Variáveis

```
Age            -0.000000
Sex            -0.090213
BP              0.565471
Cholesterol     0.160856
Na_to_K        -1.098116
dtype: float64
```

Máquina do Mizael

```
Age            -0.000000
Sex            -0.000000
BP              0.475343
Cholesterol     0.058365
Na_to_K        -1.009271
dtype: float64
```

Máquina do Glauber

Discrepância da Questão 4 - Crosstab

Drug	0	1	2	3	4
Cluster					
0	18	6	6	7	27
1	37	3	0	0	0
2	12	8	4	0	19
3	24	6	6	9	8

Máquina do Mizael

Drug	0	1	2	3	4
Cluster					
0	37	11	8	0	12
1	24	6	6	9	17
2	18	6	2	0	0
3	12	0	0	7	25

Máquina do Glauber

RESULTADOS E DISCUSSÕES

QUESTÃO 1 - Na AV1 você realizou uma análise do KNN para descobrir o melhor valor de k e também a forma mais adequada de determinar a métrica de distância. Utilizando o *GridSearchCV* que está disponível na Scikit-Learn, realize o mesmo processo para descobrir qual a melhor parametrização no processo de classificação do seu dataset. Gere os dados de acertos completos e faça uma análise do resultado. Verifique se o resultado obtido na AV1 é o mesmo que você obteve nesta AV2.

PROCESSO

- Carregamento do dataset drug200.csv.
- Codificação de variáveis categóricas (Sex, BP, Cholesterol, Drug) usando LabelEncoder.
- Separação das features (X) e do target (y).
- Divisão do dataset em conjuntos de treino e teste (70% treino, 30% teste).
- Padronização das features com StandardScaler.
- Definição do modelo KNN e busca de hiperparâmetros usando GridSearchCV.
- Treinamento do modelo e avaliação da acurácia no conjunto de teste.

RESULTADOS DE QUESTÃO

AV2 - Melhor Parâmetro e Melhor K

```
Melhores parâmetros: {'metric': 'euclidean', 'n_neighbors': 9}
Melhor acurácia no treino: 0.84
Acurácia no conjunto de teste: 0.88
```

AV1 - Cálculo do Melhor Parâmetro e Melhor K de Cada

```
Melhor k para mahalanobis: 1 com acurácia de 0.95
Melhor k para chebyshev: 3 com acurácia de 0.70
Melhor k para manhattan: 1 com acurácia de 0.75
Melhor k para euclidean: 3 com acurácia de 0.68
```

Na AV1, a métrica que apresentou a melhor acurácia foi a *Mahalanobis*, com uma acurácia de 0.95. No entanto, na AV2, utilizando *GridSearchCV*, a métrica escolhida foi a *Euclidiana*, que alcançou uma acurácia de 0.88 no conjunto de teste. Em relação ao valor de k, na AV1, o melhor k foi 1 referente a métrica *Mahalanobis*. Na AV2, o melhor k encontrado foi 9, com a métrica *Euclidiana*.

QUESTÃO 2 - Sem considerar a coluna alvo do seu dataset, faça uma análise para descobrir a quantidade ideal de clusters que deve ser feita. Considerem usar o método do cotovelo e da silhueta.

PROCESSO

- Carregamento do dataset drug200.csv.
- Codificação de variáveis categóricas.
- Remoção da coluna alvo 'Drug' e padronização dos dados.
- Cálculo da Inertia para diferentes valores de K (1 a 10).
- Plotagem do gráfico do método do cotovelo para visualizar a Inertia.
- Cálculo do índice de silhueta para valores de K (2 a 10) e plotagem do gráfico correspondente.

RESULTADO DA QUESTÃO

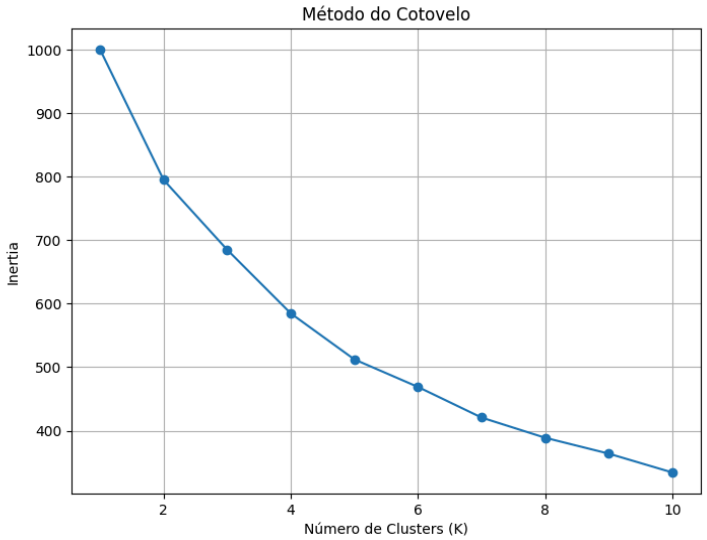

No gráfico ao lado, observa-se que a taxa de redução da inércia começa a diminuir significativamente entre K=3 e K=4, sugerindo que K=4 pode ser o número ideal de clusters. Após esse ponto, a adição de mais clusters resulta em uma diminuição significativa da inércia.

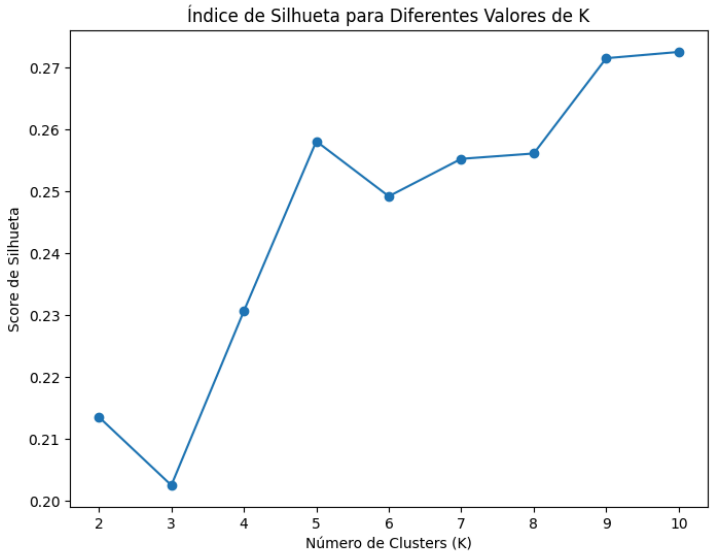

Observa-se no gráfico ao lado que o índice de silhueta atinge seu valor máximo próximo a K=10. Isso sugere que 10 clusters podem ser a quantidade ideal para o dataset, pois proporciona uma boa separação entre os grupos.

QUESTÃO 3 - Escolha os dois atributos mais relevantes utilizando o método de Lasso e recalcule a quantidade de clusters com método do cotovelo e silhueta. Mudou a quantidade de cluster em relação à questão anterior? Se k diferentes para os dois métodos de determinação da quantidade de clusters, faça dois scatterplots e faça uma análise visual.

PROCESSO

- Carregamento e pré-processamento do dataset.
- Aplicação do Lasso para seleção de atributos relevantes.
- Identificação dos dois atributos mais relevantes.
- Filtragem dos dados para incluir apenas os atributos selecionados.
- Aplicação do método do cotovelo e cálculo da Inertia.
- Cálculo do índice de silhueta para os atributos selecionados.

RESULTADO DA QUESTÃO

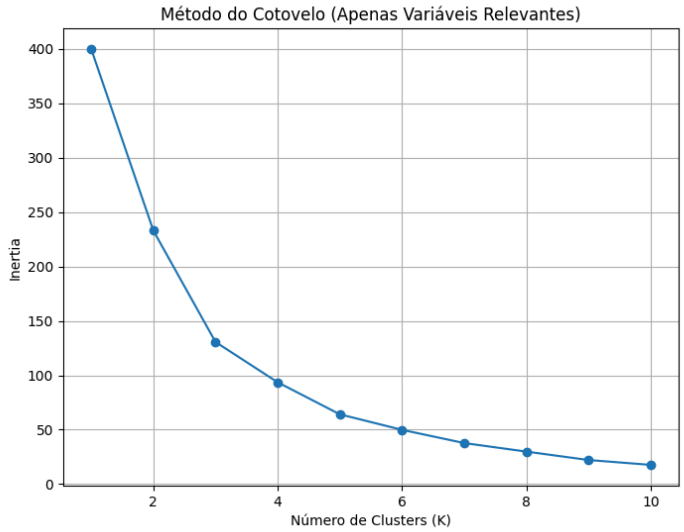

Na figura, observa-se que a taxa de redução da inércia começa a diminuir significativamente entre K=3 e K=4, sugerindo que K=4 possa ser o número ideal de clusters. Após esse ponto, a adição de mais clusters resulta em uma diminuição significativa da inércia.

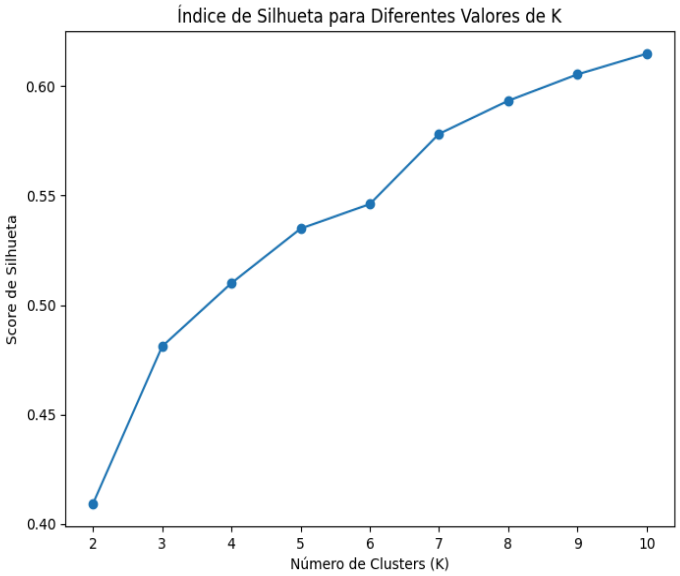

Observa-se que o índice de silhueta aumenta à medida que o número de clusters cresce, atingindo um valor próximo a 0,60 quando K=10.

```
Coeficientes Lasso:
Age          -0.000000
Sex          -0.000000
BP            0.475343
Cholesterol   0.058365
Na_to_K      -1.009271
dtype: float64
```

A análise dos coeficientes Lasso destacou que a Pressão Arterial (BP) e a Relação Sódio-Potássio (Na_to_K) são as variáveis mais importantes para prever o tipo de medicamento prescrito, com coeficientes de 0,475 e -1,099, respectivamente. Por outro lado, a Idade (Age) e o Sexo (Sex) mostraram-se pouco relevantes, apresentando coeficientes próximos de zero

OBS: Os scatterplots não foram elaborados, pois o melhor resultado da questão 3 é o mesmo da questão 2.

QUESTÃO 4 - Faça um crosstab para que possamos identificar como ficou a distribuição de cluster de acordo com classes presentes na coluna alvo do seu dataset. Utilize o K means e utilize o k obtido pelo índice de silhueta.

PROCESSO

- Carregamento do dataset e pré-processamento.
- Codificação de variáveis categóricas.
- Separação das features e do target.
- Padronização das features.
- Aplicação do K-Means com 10 clusters.
- Adição dos rótulos dos clusters ao DataFrame original.
- Criação de uma tabela cruzada (crosstab) para analisar a relação entre clusters e a variável alvo 'Drug'.

RESULTADO DA QUESTÃO

Drug	0	1	2	3	4
Cluster					
0	18	6	6	7	27
1	37	3	0	0	0
2	12	8	4	0	19
3	24	6	6	9	8

A análise dos dados do crosstab ao lado, revela diferenças claras na prescrição de medicamentos entre os grupos de pacientes. No Cluster 0 e no Cluster 3, a maioria dos pacientes recebeu o medicamento DrugY, com uma quantidade considerável também utilizando o medicamento drugA. Em contraste, o Cluster 1 se destaca pela forte associação com o medicamento drugA, com poucos pacientes utilizando outras opções. Já o Cluster 2 apresenta uma distribuição mais equilibrada entre os medicamentos, embora ainda tenha uma maior concentração de pacientes que receberam o drugA.

CONCLUSÃO

Este relatório analisou o dataset "Drug Classification" usando técnicas de Inteligência Artificial para classificar medicamentos com base nas características dos pacientes.

Na questão 1 foi feita otimização do modelo KNN com GridSearchCV revelou que a métrica Euclidiana e k=9 foram os melhores parâmetros, em contraste com os resultados da AV1, que indicaram a métrica Mahalanobis e k=1.

Na questão 2, a quantidade ideal de clusters variou entre 4 e 10, com o método do cotovelo sugerindo K=4 e o índice de silhueta indicando K=10 para uma boa separação.

Na questão 3 foi feita a análise de Lasso destacou a Pressão Arterial (BP) e a Relação Sódio-Potássio (Na_to_K) como as variáveis mais relevantes. A recalibração dos clusters com essas variáveis confirmou K=4 pelo método do cotovelo e K=10 pelo índice de silhueta.

E a questão 4, a análise da distribuição dos clusters revelou diferenças na prescrição de medicamentos, com os clusters 0 e 3 predominando o medicamento DrugY, o cluster 1 associado ao drugA, e o cluster 2 apresentando uma distribuição mais equilibrada.

PRÓXIMOS PASSOS

Para futuras análises, recomenda-se realizar testes adicionais em diferentes máquinas para validar os resultados, considerando possíveis discrepâncias nos dados. Além disso, é importante explorar outras técnicas de clusterização e classificação para comparar e aprimorar os resultados. Deve-se também investigar mais a fundo as variáveis selecionadas pelo método Lasso e sua influência na escolha do medicamento, a fim de identificar padrões mais específicos. Por fim, aplicar esses modelos em cenários reais pode oferecer insights valiosos para melhorar a tomada de decisão na área da saúde.