UNIVERSIDADE FEDERAL DO CEARÁ

TECHNICAL REPORT

Alunos: Francisco de Paula Mesquita Júnior e Natércia de Sousa Félix

1. Introdução

Este relatório apresenta a análise e implementação de modelos de aprendizado supervisionado utilizando um dataset voltado para a previsão de diabetes em pacientes. O objetivo principal é desenvolver modelos de classificação capazes de diagnosticar a presença da doença com base em medidas diagnósticas específicas.

Dataset

Dataset Utilizado

- ***Fonte:*** *National Institute of Diabetes and Digestive and Kidney Diseases.*
- ***Descrição:*** *O dataset inclui diversas variáveis médicas preditoras e uma variável alvo (Outcome), que indica a presença ou ausência de diabetes. Os dados foram coletados exclusivamente de mulheres com pelo menos 21 anos de idade e pertencentes à etnia Pima Indian.*
- ***Objetivo:*** *Prever a ocorrência de diabetes com base nos atributos fornecidos.*

2. Observações

3. Resultados e discussão

Questão 1 - Implementação do KNN com Ajuste de Hiperparâmetros

Essa questão tem como objetivo desenvolver um modelo de aprendizado de máquina para prever a presença de diabetes em pacientes, utilizando o algoritmo K-Nearest Neighbors (KNN).

Etapas:

1. ***Carregar e manipular o dataset*** *utilizando a biblioteca pandas, removendo valores ausentes.*
2. ***Pré-processar os dados****, aplicando* ***normalização*** *com StandardScaler para padronizar as variáveis.*
3. ***Dividir o dataset*** *em conjuntos de treino e teste para avaliação do modelo.*

4. ***Ajustar os hiperparâmetros*** *do KNN usando GridSearchCV, testando diferentes números de vizinhos (**k**) e métricas de distância.*
5. ***Treinar e validar*** *o modelo com* ***validação cruzada****, identificando a melhor configuração do KNN.*
6. ***Avaliar o desempenho*** *no conjunto de teste, calculando* ***acurácia, precisão, recall e F1-score****.*

A seguir, um fluxograma ilustrando o processo:

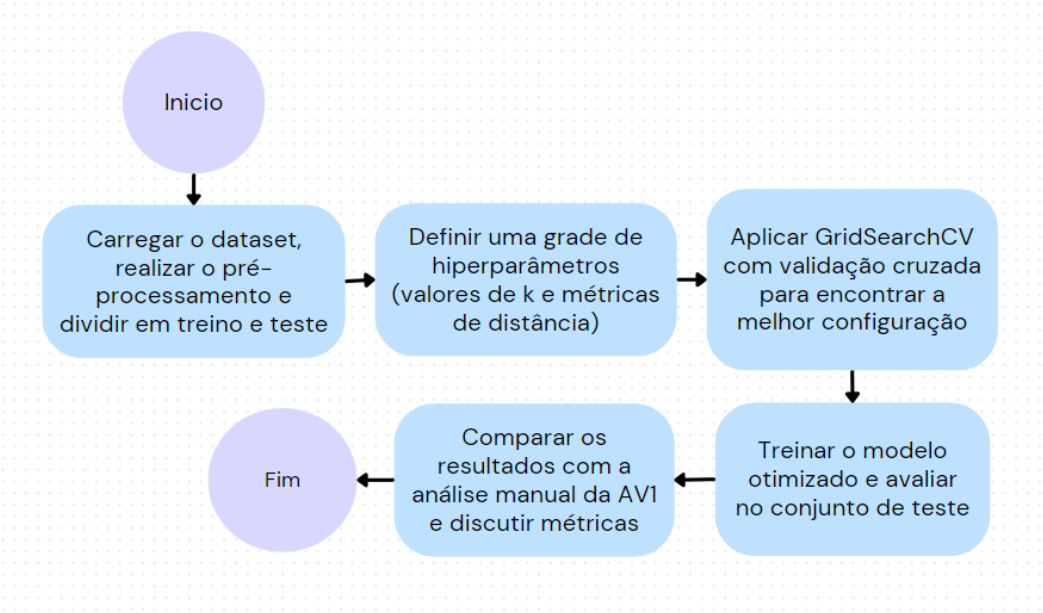

[Figura 1- Fluxograma do Processo].

Questão 2 - Determinação do Número Ideal de Clusters

Para definir a quantidade ideal de clusters no conjunto de dados, foram utilizados dois métodos amplamente reconhecidos: Método do Cotovelo e Coeficiente de Silhueta. Esses métodos permitem avaliar o comportamento do K-Means em diferentes valores de k e identificar o ponto ideal de segmentação.

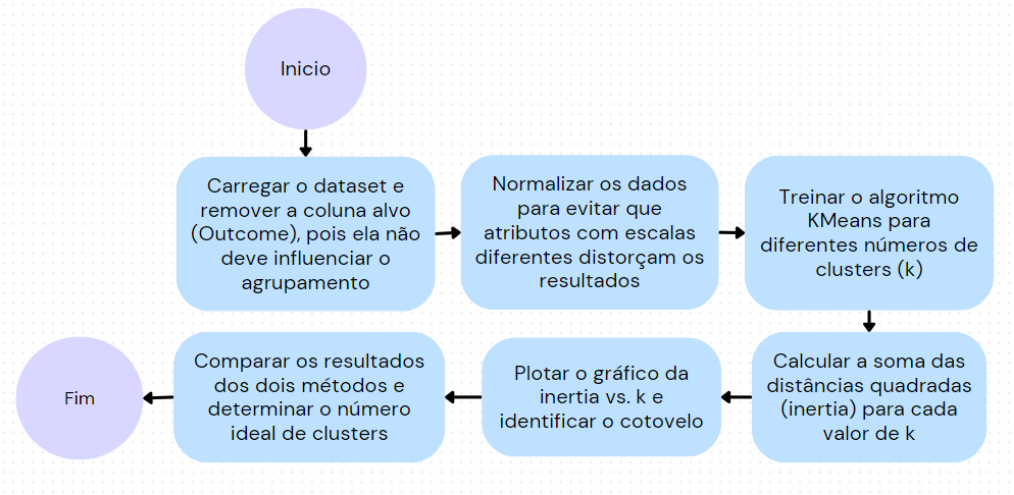

[Figura 2- Fluxograma do Processo].

Procedimentos:

Pré-processamento:

- *A variável alvo Outcome foi removida para garantir que o modelo realizasse a segmentação sem influência dos rótulos reais.*
- *Os dados foram padronizados utilizando StandardScaler, assegurando que todas as variáveis tivessem a mesma escala e evitassem distorções no agrupamento.*

Aplicação do K-Means:

- *O algoritmo K-Means foi testado para diferentes valores de k, variando de 2 a 10, permitindo analisar o comportamento do modelo em diferentes níveis de segmentação.*
- *Para cada valor de k, foram calculadas duas métricas importantes:*
    - ***Inércia (Elbow Method):*** *Mede a soma das distâncias dos pontos ao centróide mais próximo, permitindo identificar um ponto de inflexão onde o acréscimo de novos clusters deixa de trazer melhorias significativas.*
    - ***Coeficiente de Silhueta:*** *Avalia o quão bem os pontos estão agrupados, comparando a proximidade dentro do próprio cluster e em relação aos demais clusters.*

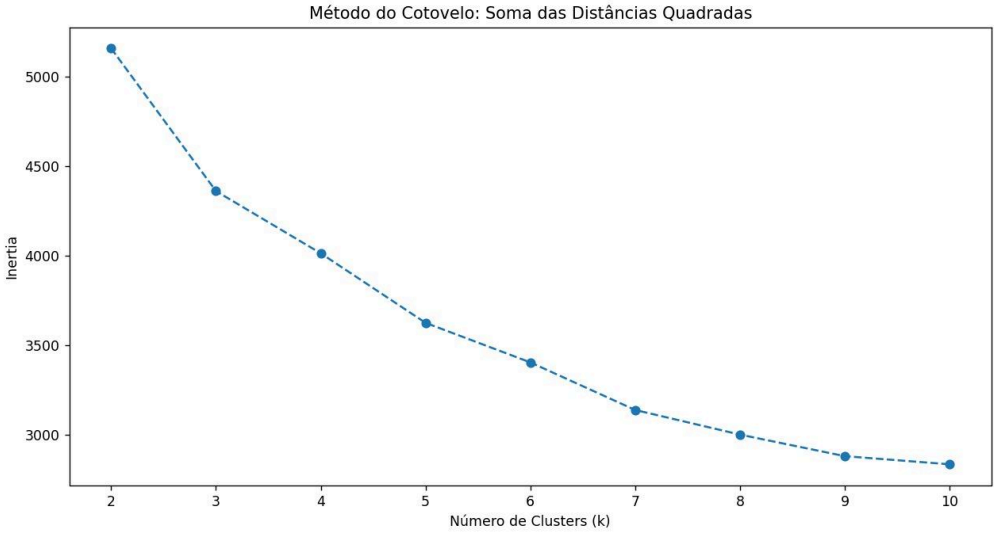

[Figura 3- Método do Cotovelo].

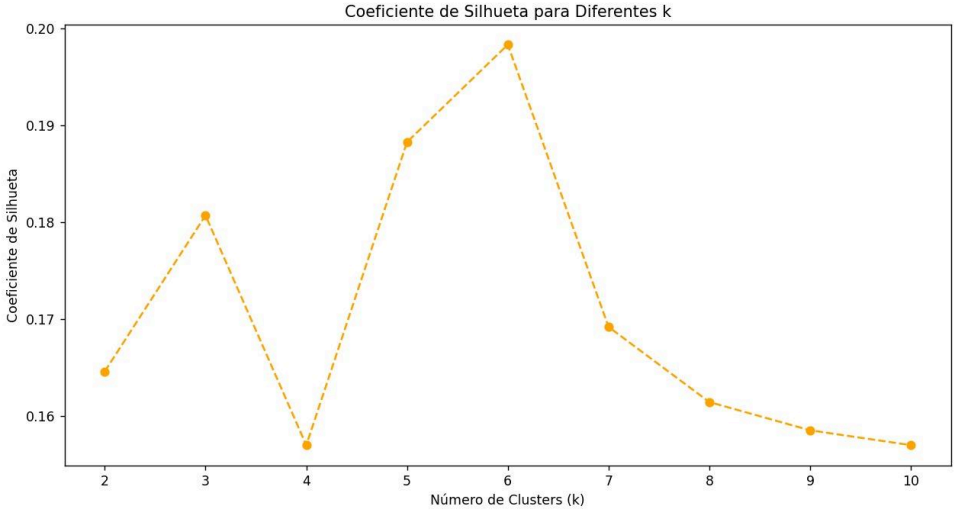

[Figura 4 - Coeficiente de Silhueta].

Resultados:

- *O gráfico do Método do Cotovelo revelou um ponto de inflexão, indicando o valor de k onde há um equilíbrio entre segmentação e simplicidade do modelo.*

- *O coeficiente de silhueta confirmou esse valor, apontando o melhor número de clusters com base na separação e coesão dos agrupamentos.*

Essa análise permitiu selecionar um valor de k que otimiza a segmentação dos dados, proporcionando uma estrutura de agrupamento mais representativa para futuras análises.

Questão 3 - Seleção de Atributos e Reavaliação dos Clusters

Nesta etapa, foi aplicado o método de Lasso (Least Absolute Shrinkage and Selection Operator) para identificar os atributos mais relevantes na segmentação dos dados. A partir dessa seleção, a análise de clusters foi refeita para avaliar se a remoção de variáveis menos significativas impactaria a qualidade da segmentação.

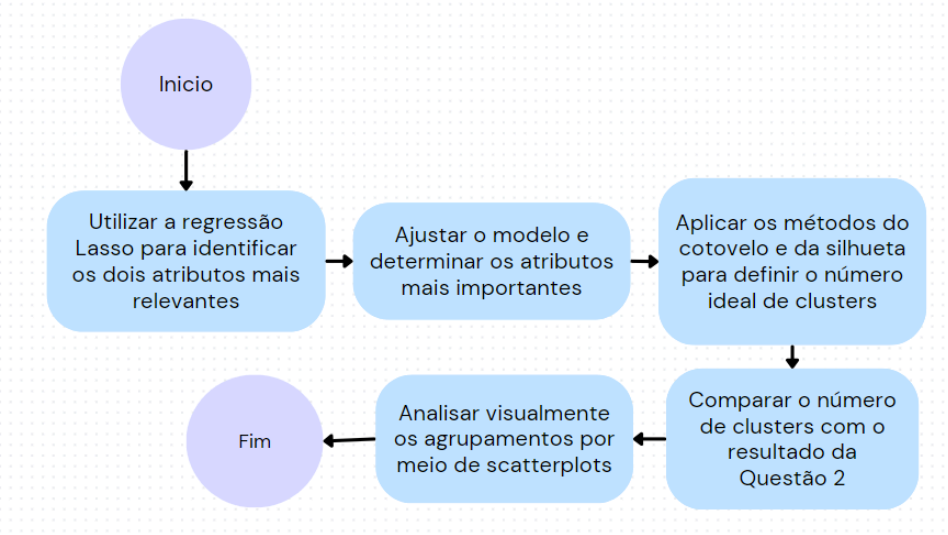

[Figura 5 - Fluxograma do Processo].

Procedimentos:

Seleção de atributos:

- *O algoritmo Lasso (Least Absolute Shrinkage and Selection Operator) foi aplicado para identificar os dois atributos mais relevantes, eliminando variáveis com menor impacto na segmentação.*

Reavaliação do número de clusters:

- *O algoritmo K-Means foi reaplicado utilizando apenas os atributos selecionados, reduzindo a dimensionalidade do problema.*
- *O número ideal de clusters (k) foi recalculado utilizando os métodos do Cotovelo e Silhueta, avaliando se a remoção de variáveis afetou a segmentação.*

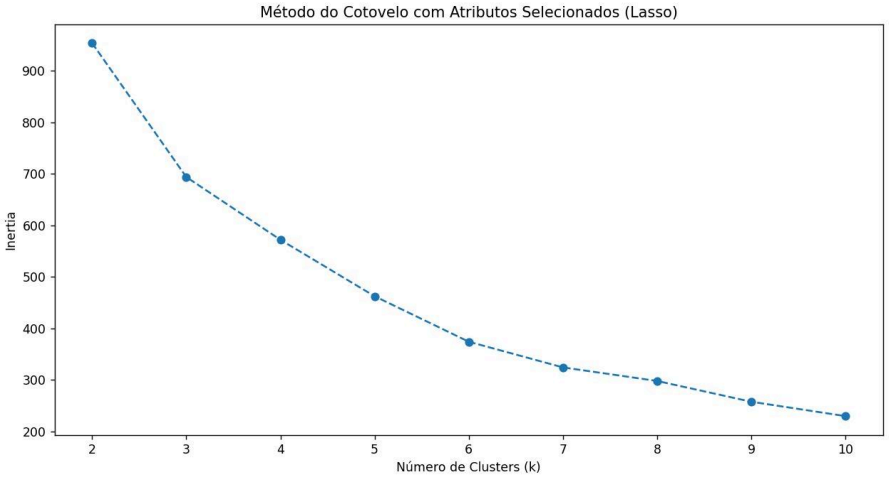

.

[Figura 6 - Método do Cotovelo].

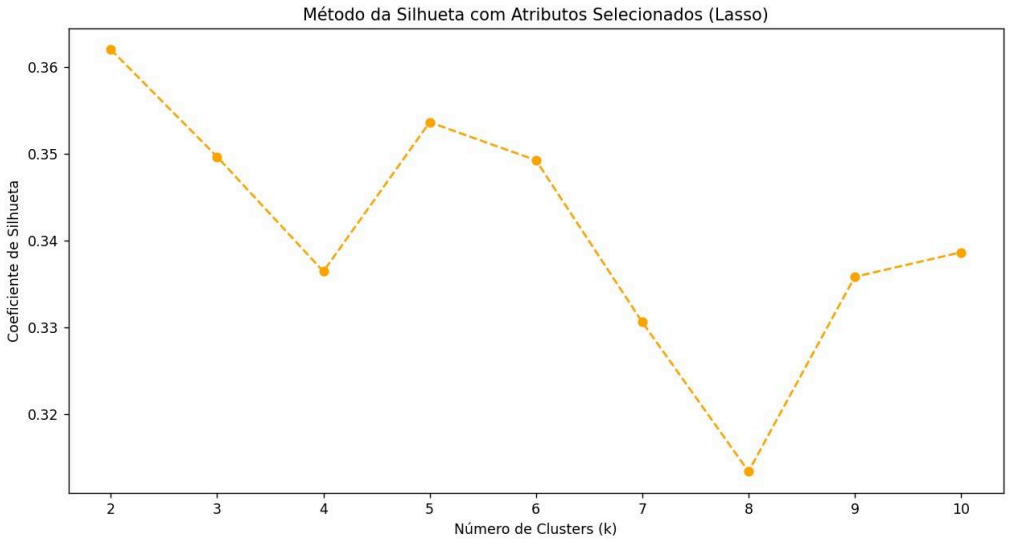

[Figura 7 - Método de Silhueta].

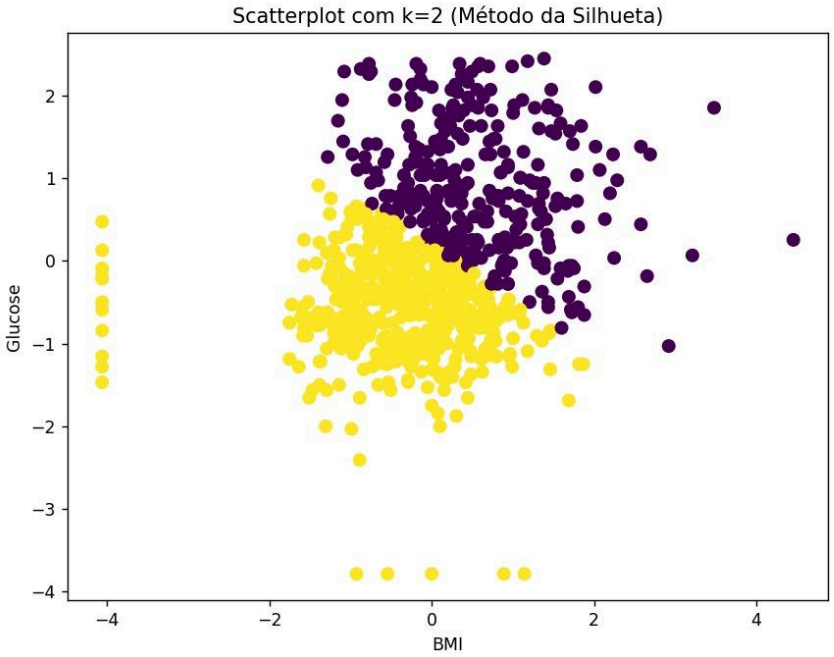

[Figura 8 -].

[Figura 9 -].

Resultados

- *A aplicação do Lasso permitiu selecionar os atributos mais relevantes, contribuindo para uma análise mais focada.*
- *A reavaliação do número ideal de clusters indicou que o k ideal pode ter sofrido alterações em relação à análise inicial da Questão 2.*
- *A visualização gráfica dos novos agrupamentos possibilitou uma comparação detalhada entre os clusters gerados antes e depois da seleção de atributos, verificando se houve uma segmentação mais eficiente.*

Essa abordagem ajudou a reduzir a complexidade do modelo e aprimorar a qualidade da segmentação, garantindo uma estrutura de clusters mais representativa.

Questão 4 - Comparação de Clusters com a Classe Alvo

Nesta etapa, foi analisada a relação entre os clusters gerados pelo K-Means e a variável Outcome, que indica a presença ou ausência de diabetes. O objetivo foi avaliar se os grupos formados pelo algoritmo refletem adequadamente as classes reais.

saída:

LABELS / VARIETIES	0	1
0	421	128
1	79	86

Procedimentos

Pré-processamento:

- *A variável alvo Outcome foi separada do conjunto de dados para que o algoritmo de clustering operasse de forma não supervisionada.*
- *Os atributos foram normalizados utilizando StandardScaler, garantindo que todas as variáveis tivessem a mesma escala e evitassem viés na formação dos clusters.*

Agrupamento com K-Means:

- *O algoritmo K-Means foi aplicado com k = 2, assumindo a existência de dois grupos principais (diabéticos e não diabéticos).*
- *Os clusters foram analisados para verificar se refletiam corretamente a separação entre os pacientes saudáveis e os diagnosticados com diabetes.*

Análise de correspondência:

- *Foi gerada uma tabela cruzada para comparar os clusters resultantes com a variável Outcome, permitindo identificar a proporção de pacientes diabéticos e não diabéticos em cada cluster.*
- *A distribuição mostrou que o Cluster 0 contém um número semelhante de pacientes saudáveis (148) e diabéticos (156), enquanto o Cluster 1 apresentou uma predominância de pacientes saudáveis (352) em relação aos diabéticos (112). Isso sugere que o modelo não conseguiu segmentar claramente os dois grupos.*

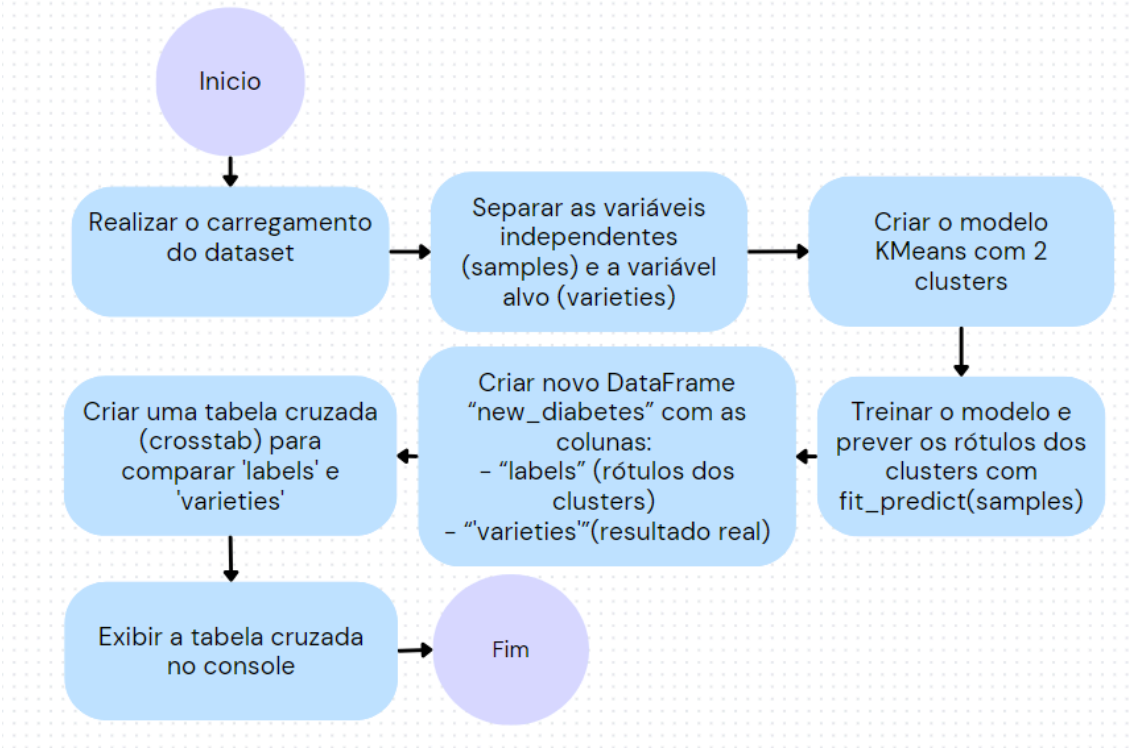

[Figura 10 - Fluxograma do Processo].

Resultados

Os resultados indicam que o K-Means não foi eficaz na separação dos pacientes diabéticos e não diabéticos. Como um algoritmo de aprendizado não supervisionado, ele não leva em consideração a variável alvo (Outcome) durante o agrupamento, o que significa que os clusters são formados apenas com base na similaridade matemática entre as amostras. Se os pacientes diabéticos e não diabéticos não estiverem bem separados no espaço de variáveis, o modelo pode falhar na distinção.

Além disso, a presença significativa de pacientes de ambas as classes em cada cluster sugere uma possível sobreposição entre as classes, indicando que os atributos escolhidos podem não ser suficientes para uma segmentação eficiente utilizando apenas K-Means. Para melhorar a separação, seria necessário explorar técnicas de seleção de atributos mais relevantes ou utilizar modelos supervisionados que considerem os rótulos reais dos dados.

4. Conclusões

A análise realizada neste estudo permitiu verificar a eficiência dos modelos utilizados para previsão e segmentação de dados relacionados ao diabetes. O modelo KNN demonstrou um desempenho satisfatório, e o ajuste de hiperparâmetros foi fundamental para sua otimização. Além disso, a aplicação do método do Cotovelo e do coeficiente de silhueta revelou-se eficiente na definição do número ideal de clusters. A seleção de atributos por meio do método Lasso foi essencial para a identificação das variáveis mais relevantes, proporcionando uma melhor interpretação dos dados sem comprometer a qualidade da segmentação. Entretanto, a matriz de contingência indicou certa sobreposição entre os clusters gerados e as classes reais, evidenciando a necessidade de ajustes adicionais na modelagem para melhorar a separação das amostras. Além disso, a análise do dataset revelou que algumas variáveis possuem valores nulos representados como zero, especialmente em atributos como nível de glicose, pressão arterial e insulina. Esse problema pode ter impactado a performance dos modelos e sugere a necessidade de um pré-processamento mais detalhado.

5. Próximos passos

Dataset:

- *Identificar e tratar valores nulos representados como zero, substituindo-os por valores estatísticos mais adequados.*
- *Explorar técnicas avançadas de pré-processamento, como remoção de outliers e criação de novas variáveis derivadas.*
- *Analisar a distribuição dos atributos e considerar a normalização ou padronização para melhorar a performance dos modelos.*

Geral:

- *Testar outros algoritmos de classificação, como Random Forest e SVM, para comparar a performance com o KNN.*
- *Avaliar métodos adicionais de seleção de atributos, como PCA, para verificar se a redução dimensional melhora a segmentação.*
- *Explorar técnicas de aprendizado profundo, como redes neurais, para identificar padrões mais complexos nos dados.*

- *Realizar um estudo aprofundado sobre a interpretabilidade dos modelos para garantir que os resultados sejam compreensíveis e aplicáveis em contextos reais.*
- *Refinar o pipeline de pré-processamento para aprimorar a qualidade dos dados e, consequentemente, a eficácia dos modelos.*