UNIVERSIDADE FEDERAL DO CEARÁ

TECHNICAL REPORT

Alunos: Eryka Rodrigues de Sousa, Gabriel Sousa Braga

1. Introdução

Este relatório apresenta uma análise detalhada do dataset "Gender Classification", disponível no Kaggle. O objetivo é aplicar técnicas de aprendizado de máquina para realizar classificações e agrupamentos nos dados, avaliando a melhor parametrização para o KNN, determinando a quantidade ideal de clusters e analisando a distribuição dos grupos formados.

As principais etapas incluem:

- *Uso do GridSearchCV para encontrar a melhor parametrização do KNN.*
- *Determinação da quantidade ideal de clusters usando os métodos do cotovelo e da silhueta.*
- *Seleção dos dois atributos mais relevantes com o método Lasso e nova análise de clusters.*
- *Criação de um crosstab para visualizar a distribuição dos clusters em relação à classe alvo.*

Descrição do Dataset

O dataset utilizado contém informações sobre características físicas e gênero dos indivíduos. As principais colunas disponíveis são:

- **Long Hair**: Indica se o indivíduo tem cabelo longo (0 ou 1).
- **Forehead Width**: Largura da testa.
- **Forehead Height**: Altura da testa.
- **Nose Width**: Largura do nariz.
- **Nose Length**: Comprimento do nariz.
- **Lip Thickness**: Espessura do lábio.
- **Distance Between Eyes**: Distância entre os olhos.
- **Gender**: Classe alvo (Masculino ou Feminino).

A análise envolve pré-processamento dos dados, normalização e aplicação de algoritmos de aprendizado de máquina para extrair insights relevantes.

2. Observações

Não enfrentamos dificuldades no processo que sejam relevantes.

3. Resultados e discussão

Questão 1: Otimização do KNN com GridSearchCV

Nesta etapa, utilizamos o GridSearchCV para encontrar a melhor configuração para o algoritmo KNN, testando diferentes valores de k e métricas de distância (Euclidiana, Manhattan e Minkowski).

Metodologia:

- *Testamos múltiplos valores de k e diferentes métricas de distância.*
- *Utilizamos a validação cruzada para garantir a melhor escolha dos parâmetros.*

Resultados

```
Melhores parâmetros: {'metric': 'manhattan', 'n_neighbors': 20}
Acurácia no conjunto de teste: 0.9660339660339661
Relatório de classificação:
              precision    recall  f1-score   support

      Female       0.95      0.98      0.97       502
        Male       0.98      0.95      0.97       499

    accuracy                           0.97      1001
   macro avg       0.97      0.97      0.97      1001
weighted avg       0.97      0.97      0.97      1001
```

Questão 2: Determinação da Quantidade Ideal de Clusters

Usamos os métodos do cotovelo e da silhueta para determinar o número ideal de clusters sem considerar a coluna alvo.

Metodologia:

- *Calculamos a inércia para diferentes valores de k para gerar o gráfico do cotovelo.*
- *Avaliamos o coeficiente de silhueta para medir a separação entre clusters.*

Resultados

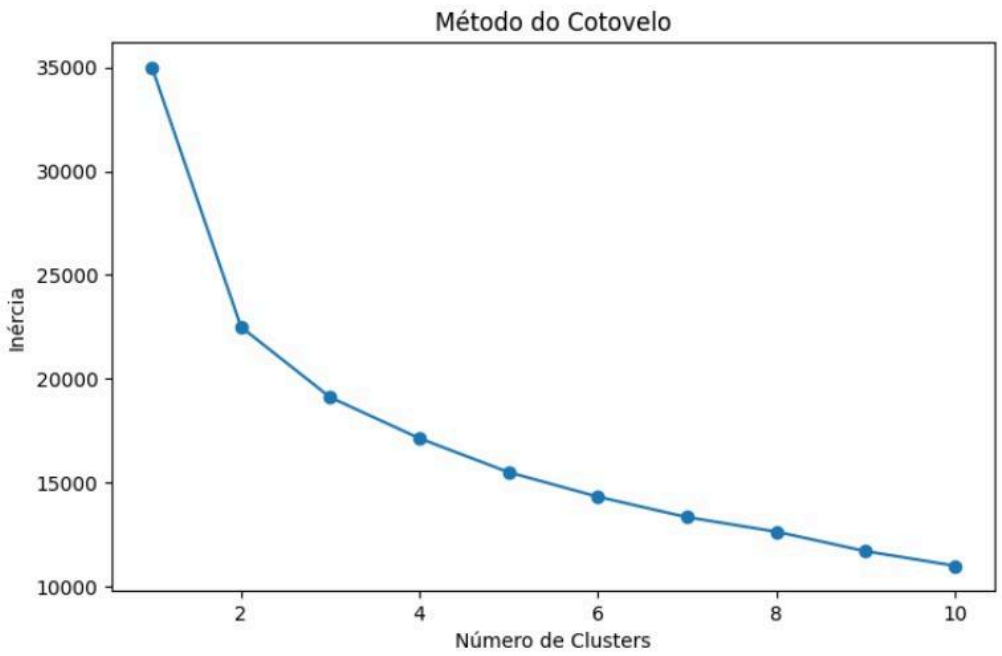

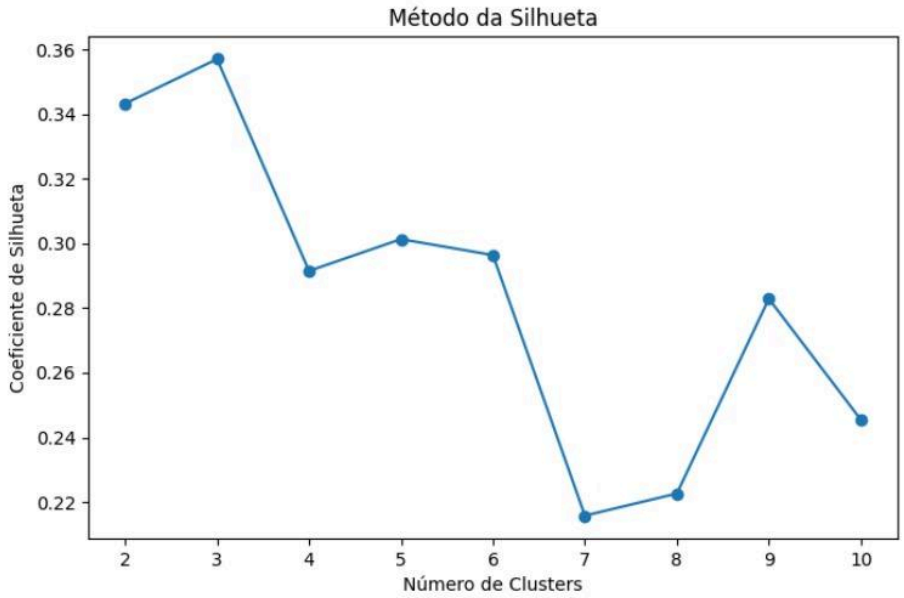

Questão 3: Seleção de Atributos com Lasso e Nova Análise de Clusters

Utilizamos a regressão Lasso para identificar os dois atributos mais relevantes e refizemos a análise de clusters com os métodos do cotovelo e da silhueta.

Metodologia:

- *Aplicamos o método Lasso para seleção de atributos.*
- *Recalculamos os clusters considerando apenas os dois atributos mais relevantes.*
- *Comparamos os resultados com a análise anterior.*

Resultados

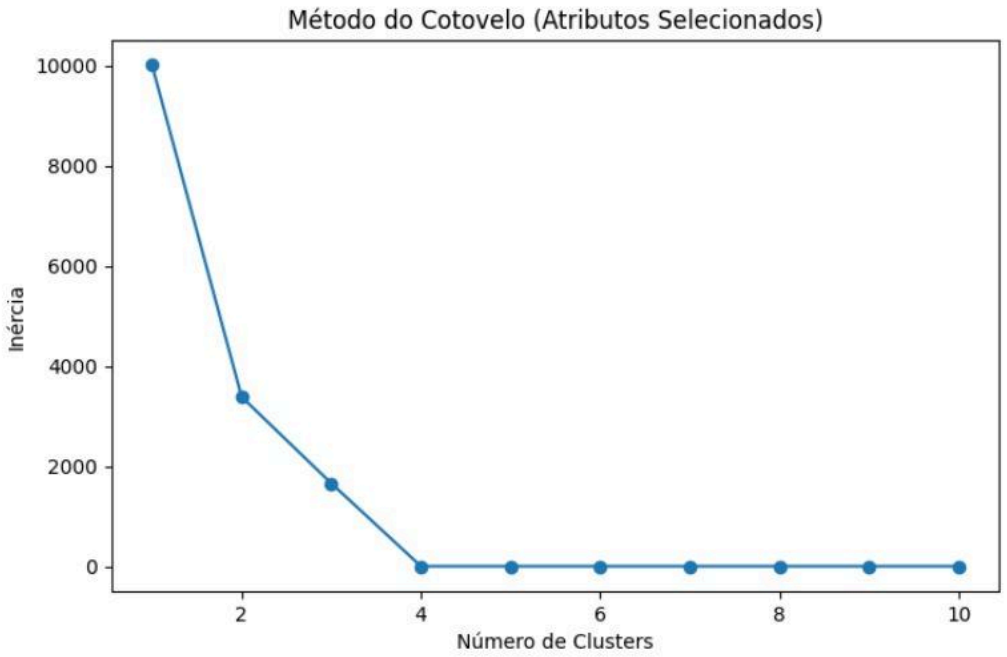

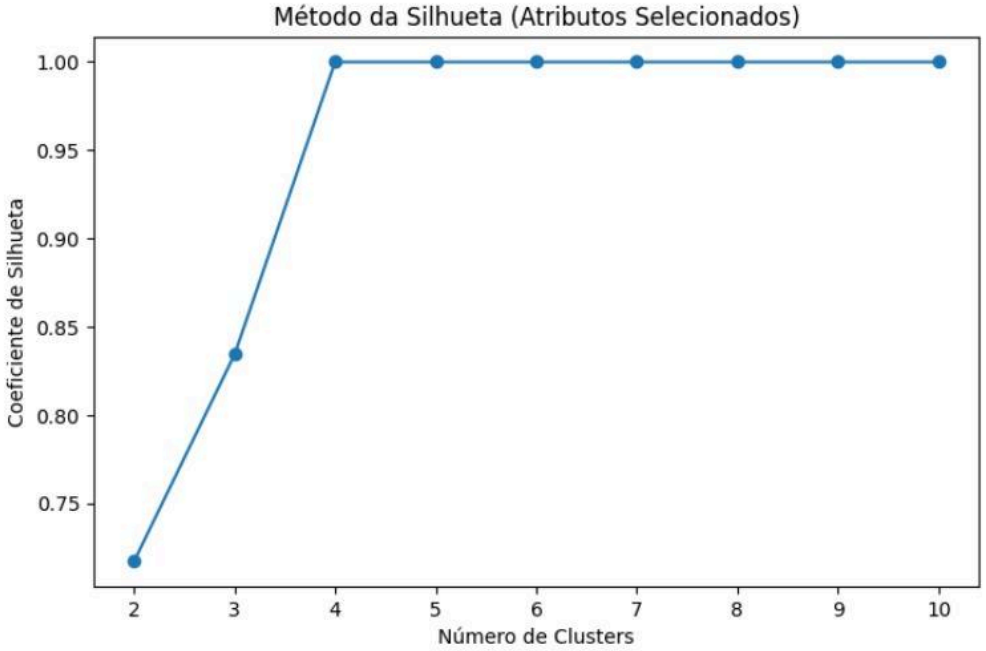

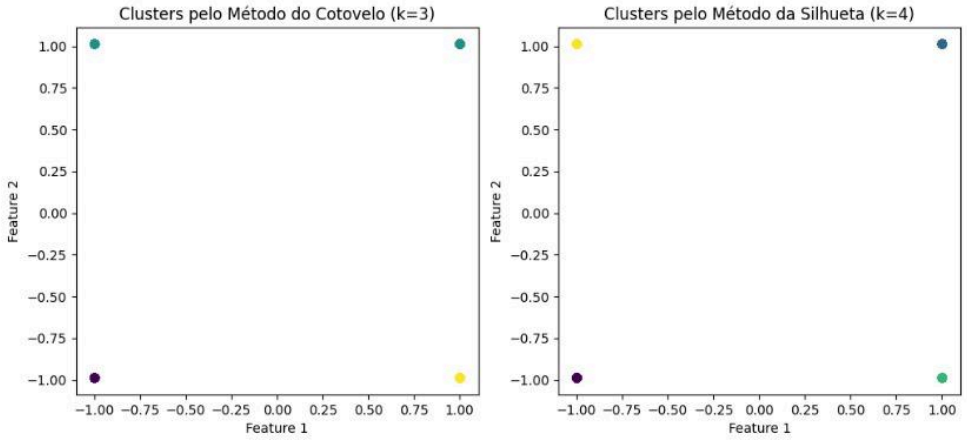

Questão 4: Crosstab da Distribuição dos Clusters por Classe Alvo

Criamos uma tabela cruzada para entender como os clusters obtidos pelo método da silhueta se distribuem em relação à classe alvo.

Metodologia:

- *Aplicamos KMeans com o k determinado pelo índice de silhueta.*

- *Geramos uma tabela cruzada comparando os clusters com a variável alvo.*

Resultados

```
Distribuição de Clusters por Classe:
gender      0     1
cluster
0        1941    39
1          31  1913
2         273   278
3         256   270
```

4. Conclusões

Os resultados obtidos no trabalho indicaram que:

- *O uso do GridSearchCV permitiu otimizar o KNN e encontrar os melhores parâmetros.*
- *O método do cotovelo e da silhueta foram eficazes para determinar o número ideal de clusters.*
- *A seleção de atributos com Lasso alterou os resultados da análise de clusters, destacando a importância da escolha das features.*
- *O crosstab revelou a relação entre os clusters e a classe alvo, permitindo avaliar a segmentação dos dados.*

5. Próximos passos

Para dar continuidade ao projeto, sugere-se:

- *Aplicar outros algoritmos de clustering como DBSCAN para comparar os resultados.*
- *Explorar diferentes valores de alpha no Lasso para verificar mudanças na seleção de atributos.*
- *Testar outras métricas de avaliação para clustering, como Davies-Bouldin Index.*
- *Implementar técnicas de redução de dimensionalidade como PCA antes do clustering.*